



دانشگاه شهید بهشتی

دانشکده مهندسی و علوم کامپیوتر

راه کاری مبتنی بر یادگیری ماشین برای پیش بینی مهارت های افراد در آینده در وبسایت های پرسش و پاسخ اجتماعی

پایان نامه کارشناسی ارشد مهندسی کامپیوتر
گرایش نرم افزار

نگارش

سینا محمدی

استاد راهنما

دکتر محمود نشاطی

تابستان ۱۴۰۴



دانشگاه شهید بهشتی
دانشکده مهندسی و علوم کامپیوتر

پایان نامه کارشناسی ارشد مهندسی کامپیوتر - گرایش نرم افزار
تحت عنوان:

راه کاری مبتنی بر یادگیری ماشین برای پیش بینی مهارت های افراد در آینده در وبسایت های
پرسش و پاسخ اجتماعی

در تاریخ
پایان نامه دانشجو، سینا محمدی، توسط کمیته تخصصی داوران مورد بررسی و تصویب نهایی قرار
گرفت.

امضا	نام و نام خانوادگی	۱- استاد راهنما اول:
امضا	نام و نام خانوادگی	۲- استاد راهنما دوم:
امضا	نام و نام خانوادگی	۳- استاد مشاور:
امضا	نام و نام خانوادگی	۴- استاد داور (داخلی):
امضا	نام و نام خانوادگی	۵- استاد داور (خارجی):
امضا	نام و نام خانوادگی	۶- نماینده تحصیلات تکمیلی:

کلیه حقوق مادی مترتب بر نتایج مطالعات،
ابتکارات و نوآوری‌های ناشی از تحقیق موضوع
این پایان‌نامه متعلق به دانشگاه شهید بهشتی
می‌باشد.

به نام خدا

نام و نام خانوادگی: سينا محمدی

عنوان پایان نامه: راه کاری مبتنی بر یادگیری ماشین برای پیش بینی مهارت های افراد در آینده در وبسایت های

پرسش و پاسخ اجتماعی

استاد راهنما: دکتر محمود نشاطی

اینجانب سينا محمدی تهیه کننده پایان نامه کارشناسی ارشد حاضر، خود را ملزم به حفظ امانت داری و قدردانی از زحمات سایر محققین و نویسندگان بنابر قانون Copyright می دانم. بدین وسیله اعلام می نمایم که مسئولیت کلیه مطالب درج شده با اینجانب می باشد و در صورت استفاده از اشکال، جداول و مطالب سایر منابع، بلافاصله مرجع آن ذکر شده و سایر مطالب از کار تحقیقاتی اینجانب استخراج گشته است و امانت داری را به صورت کامل رعایت نموده ام. در صورتی که خلاف این مطلب ثابت شود، مسئولیت کلیه عواقب قانونی با شخص اینجانب می باشد.

نام و نام خانوادگی: سينا محمدی

تاریخ و امضا:

چکیده

چکیده در اینجا قرار میگیرد

واژگان کلیدی:

فهرست مطالب

۱	۱ کلیات
۲	۲ ادبیات تحقیق
۳	۱.۲ مقدمه
۳	۲.۲ بازیابی اطلاعات
۴	۳.۲ بازیابی تخصص
۵	۴.۲ خبره
۵	۵.۲ یادگیری ماشین
۶	۶.۲ یادگیری عمیق
۶	۷.۲ سری های زمانی
۷	۸.۲ انجمن های پرسش و پاسخ
۷	۹.۲ جمع بندی
۸	۳ کارهای مرتبط
۹	۱.۳ مقدمه
۹	۲.۳ بازیابی تخصص
۹	۱.۲.۳ یافتن متخصص

۴	نتیجه گیری و کار های آینده	۱۳
	مراجع	۱۶
	واژه نامه انگلیسی به فارسی	۱۸
	واژه نامه فارسی به انگلیسی	۱۹

فهرست تصاویر

فهرست جداول

فصل ۱

کلیات

فصل ۲

ادبیات تحقیق

۱.۲ مقدمه

در این بخش ضمن آشنایی اولیه با مفاهیم کلی و بررسی کلیدواژه‌های استفاده شده در ادامه پایان‌نامه، دید بهتری نسبت به مفاهیم بازیابی اطلاعات، داده‌کاوی و همچنین یادگیری ماشین که در ادامه فصل‌های پایان‌نامه، برای بررسی مسئله مطرح شده در فصل قبل و ارائه راهکار مناسب استفاده می‌شود، کسب خواهید کرد.

۲.۲ بازیابی اطلاعات

بازیابی اطلاعات به طور بنیادی به فرایند یافتن اطلاعات مفید و مرتبط با پرسش کاربر از میان یک مجموعه اسناد اطلاق می‌شود. کاربرد اصلی این فرآیند در موتورهای جست‌وجو، سیستم‌های توصیه‌گر^۱، تحلیل شبکه‌های اجتماعی و موارد از این دست است. این فرایند به دلیل عوامل متعددی ذاتاً چالش‌برانگیز است؛ از جمله این که اطلاعات موجود در پایگاه‌های اسنادی معمولاً ساختارمند نیستند، اسناد در زبان طبیعی و به صورت آزاد نوشته می‌شوند و موضوعات بسیار متنوعی را پوشش می‌دهند. در نتیجه، سیستم‌های سنتی بازیابی اطلاعات بیشتر بر شناسایی اسنادی تمرکز داشته‌اند که احتمال می‌رود حاوی اطلاعات مفید باشند، تا ارائه مستقیم پاسخ به پرسش‌های خاص کاربر. روش کلی در این سیستم‌ها شامل نمایش هر سند و پرسش کاربر به صورت یک بردار ویژگی (مجموعه‌ای از ویژگی‌ها با وزن‌های مرتبط)، محاسبه شباهت میان آن‌ها، و سپس ارائه اسناد دارای بیشترین شباهت به کاربر است. در گذشته، نمایه‌سازی^۲ به صورت دستی و با تخصیص کلیدواژه‌ها انجام می‌شد، اما با افزایش اندازه پایگاه‌های داده این رویکرد ناکارآمد شد و روش‌های خودکار نمایه‌سازی توسعه یافتند. با رشد انفجاری اینترنت و افزایش سریع تعداد کاربران، میزبان‌ها و وبسایت‌ها، نیاز به بازیابی اطلاعات کارآمد در وب به طور چشمگیری افزایش یافت. بررسی‌ها نشان می‌دهد حدود ۸۵ درصد از کاربران اینترنت برای یافتن اطلاعات خاص از موتورهای جست‌جو استفاده می‌کنند. با این حال، همین بررسی‌ها نارضایتی قابل توجهی از عملکرد موتورهای جست‌جوی اولیه گزارش کرده‌اند؛ از جمله سرعت پایین بازیابی، تأخیرهای ارتباطی، و کیفیت پایین نتایج شامل نویز (اطلاعات غیرمرتبط) و پیوندهای معیوب. بازیابی اطلاعات در وب با پیچیدگی‌های جدیدی

^۱ system recommendation

^۲ indexing

همراه بود، زیرا حجم اسناد عمومی در وب به مراتب از پایگاه‌های داده کلاسیک بیشتر بوده و ماهیت پویای وب نمایه‌سازی جامع و مداوم را به یک چالش بزرگ تبدیل کرده است. برای مقابله با این چالش‌ها، مدل‌ها و تکنیک‌های متنوعی توسعه یافته‌اند. در مجموع، بازیابی اطلاعات نقشی حیاتی در دسترسی به داده‌ها در عصر دیجیتال دارد. با وجود موانع موجود، انتظار می‌رود که با بهره‌گیری از فناوری‌های نوین مانند هوش مصنوعی، این حوزه در آینده شاهد تحولات بیشتری باشد [۱][۲][۳].

۳.۲ بازیابی تخصص

بازیابی تخصص، شاخه‌ای از علم اطلاعات است که به شناسایی و رتبه‌بندی افراد بر اساس دانش و مهارت آن‌ها در یک حوزه خاص می‌پردازد. این حوزه به‌ویژه در مدیریت دانش، سیستم‌های توصیه‌گر و تحلیل شبکه‌های اجتماعی اهمیت دارد. هدف اصلی آن، یافتن افرادی است که بتوانند به سؤالات تخصصی پاسخ دهند یا در پروژه‌های پیچیده مشارکت کنند. این فرآیند معمولاً با تحلیل اسناد متنی، مانند مقالات علمی یا پست‌های آنلاین، و گاهی با بررسی روابط حرفه‌ای و اجتماعی افراد انجام می‌شود. برای مثال، در محیط‌های آکادمیک، تعداد استنادها و همکاری‌ها می‌تواند معیاری برای سنجش تخصص باشد. روش‌های بازیابی تخصص به سه دسته اصلی تقسیم می‌شوند: مبتنی بر متن، مبتنی بر شبکه و ترکیبی. روش‌های متنی از تکنیک‌های پردازش زبان طبیعی برای ارزیابی محتوای تولیدشده توسط افراد بهره می‌برند. در مقابل، روش‌های مبتنی بر شبکه بر ساختار روابط، مانند همکاری‌های مشترک یا تعاملات در پلتفرم‌های حرفه‌ای، تمرکز دارند. روش‌های ترکیبی که هر دو جنبه را در نظر می‌گیرند، اغلب دقت بیشتری ارائه می‌دهند. یکی از چالش‌های کلیدی این حوزه، تمایز میان تخصص واقعی و فعالیت‌های صرفاً نمایشی است که ممکن است از حضور پررنگ در شبکه‌های اجتماعی ناشی شود. علاوه بر این، مسائل اخلاقی و حریم خصوصی در استفاده از داده‌های شخصی نیز بحث‌برانگیز است و نیاز به توجه ویژه دارد. کاربردهای بازیابی تخصص شامل پیشنهاد متخصصان در سیستم‌های توصیه‌گر، شناسایی کارشناسان در سازمان‌ها و تقویت همکاری‌ها در جوامع علمی است. به طور کلی، بازیابی تخصص پتانسیل بالایی برای بهبود تصمیم‌گیری و همکاری در محیط‌های مختلف دارد و نیازمند تحقیقات بیشتری است. این بخش از پایان‌نامه تلاش کرده تا دیدگاهی جامع و در عین حال قابل فهم از این حوزه ارائه دهد. امید است که این مرور بتواند راهنمایی

اولیه برای پژوهشگران علاقه‌مند به این موضوع باشد [۴].

۴.۲ خبره

خبره به فردی گفته می‌شود که در یک یا چند حوزه مهارتی مهارت داری دانش عمیق یا تجربه عملی گسترده است. در مسائل بازیابی تخصص یا خبره یابی، خبره به کسی گفته می‌شود که توانایی حل مسائل تخصصی در یک زمینه مشخص را دارا است. با این حال این تعریف دقیقی از خبره نیست و خبره بودن یک فرد می‌تواند یک مسئله کاملاً نسبی باشد. ولی در تحقیقات انجام شده معمولاً به فردی که دارای تحصیلات رسمی، گواهی‌نامه‌های حرفه‌ای، تجربه کاری و تجربه زیسته در یک حوزه مهارتی است و منابع معتبر داده این تجربیات را تایید می‌کنند، خبره گفته می‌شود [۵].

۵.۲ یادگیری ماشین

یادگیری ماشین با هدف فراهم کردن چارچوبی نظری برای فهم ساختارها و الگوهای پنهان در داده‌ها شکل گرفته است. یادگیری ماشین در ساده‌ترین سطح خود شامل الگوریتم‌هایی است که از روی داده‌های برچسب‌خورده یا بدون برچسب قواعدی استخراج می‌کنند تا بتوانند بر اساس آن پیش‌بینی یا تحلیل انجام دهند. در روش‌های نظارت‌شده، مدل‌ها مانند رگرسیون‌های خطی یا درخت‌های تصمیم، رابطه‌ی ورودی و خروجی را از داده‌های آموزشی می‌آموزند و قابلیت تعمیم به داده‌های جدید را به دست می‌آورند. خوشه‌بندی و سایر روش‌های بدون نظارت، امکان کشف گروه‌های همگن داخل داده‌ها را فراهم می‌کنند و در مسائلی که اطلاعات برچسب‌دار محدود است، ابزار ارزشمندی هستند. مفهوم «ویژگی‌سازی» نقش محوری در بهبود کیفیت مدل‌ها دارد؛ انتخاب و تبدیل درست ویژگی‌ها می‌تواند عملکرد نهایی را تا چند برابر ارتقا دهد. چالش مهم «بیش‌برازش» هنگامی رخ می‌دهد که مدل به جای فراگیری ساختار کلی، جزئیات داده‌های آموزشی را حفظ کند که برای کنترل آن از روش‌هایی مانند اعتبارسنجی متقابل و تنظیم منظم استفاده می‌شود. در سال‌های اخیر، رویکردهای درتجمع مانند رندوم فارست و گرادیان بوستینگ به دلیل پایداری و دقت بالا، مورد توجه ویژه پژوهشگران عملی قرار گرفته‌اند. ظهور شبکه‌های عصبی عمیق با معماری‌های لایه‌لایه، قلمرو جدیدی برای حل مسائلی مثل

تشخیص تصویر و پردازش زبان طبیعی گشوده است. یادگیری انتقالی نیز امکان استفاده از دانش مدل‌های از پیش‌آموزش‌دیده را در مسائل با داده‌های محدود فراهم کرده است و به کاهش زمان آموزش کمک می‌کند. بحث تفسیرپذیری مدل‌ها به‌عنوان یک ضرورت اخلاقی و کاربردی مطرح است تا تصمیمات ماشینی قابل اعتماد و قابل توضیح باشند. در نهایت، تلفیق روش‌های کلاسیک و نوین بهترین مسیر برای غلبه بر محدودیت‌های هر رویکرد است و در ادامه فصل‌های پژوهش به بررسی جزئیات این ترکیب‌ها و روش‌های پیاده‌سازی عملی خواهیم پرداخت.

۶.۲ یادگیری عمیق

یادگیری عمیق شاخه‌ای از یادگیری ماشین است که براساس تعریف ارائه شده در کتب مرجع، با استفاده از شبکه‌های عصبی چندلایه سعی می‌کند الگوهای پیچیده و غیریکپوخت در داده‌ها را کشف کند. در این رویکرد، هر لایه از شبکه مسئول استخراج ویژگی‌هایی با سطح انتزاعی متفاوت است و ترکیب این ویژگی‌ها به مدل توانایی فهم روابط غیرخطی را می‌دهد. این روش انعطاف‌پذیری بالاتری نسبت به رویکردهای پایه یادگیری ماشین دارد و در نتیجه امکان پیاده‌سازی راه‌حل برای مسائل پیچیده‌تر و با مشخصه‌های بالاتر را دارا است [۶] [۷] [۸]. لازم به ذکر است که، در این پایان‌نامه نیز از یک شبکه عصبی چندلایه برای حل مسئله پیش‌بینی تخصص استفاده شده است.

۷.۲ سری‌های زمانی

سری‌های زمانی به عنوان چارچوبی برای تحلیل تغییرات کمی در طول بازه‌های پیوسته زمانی شناخته می‌شوند. در بررسی این داده‌ها، توجه به ساختار درونی، همچون روندهای بلندمدت و نوسانات فصلی، اهمیت ویژه‌ای دارد. ماهیت فرایندهای زمان‌مند می‌تواند ویژگی‌های پویایی و خودهمبستگی پیچیده‌ای را نشان دهد. جداسازی عناصر مختلف یک سری زمانی زمینه را برای شناخت عوامل تأثیرگذار فراهم می‌آورد. داده‌های سری زمانی در حوزه‌های گوناگون علمی، از اقتصاد تا علوم محیطی، کاربرد گسترده‌ای یافته‌اند. بررسی بقای ساختاری و ثبات واریانس در بازه‌های زمانی متفاوت، از جمله چالش‌های تحلیل این سری‌هاست. عامل زمانی به‌عنوان

بُعدی پایه‌ای، فرصت و پیچیدگی تحقیقات تجربی را هم‌زمان افزایش می‌دهد. مطالعات مربوط به تغییر رفتار متغیرها در طول زمان، دیدگاهی دینامیک و واقع‌بینانه ارائه می‌کند. درک توالی‌های زمانی، بنیانی برای تحلیل علّی و تبیین روابط متغیرها به حساب می‌آید. تحلیل دقیق سری‌های زمانی دیدی منسجم از سفر داده در طول زمان در اختیار پژوهشگر می‌گذارد. [۹]

۸.۲ انجمن‌های پرسش‌وپاسخ

انجمن‌های پرسش‌وپاسخ به عنوان سکویی برای تبادل دانش میان کاربران، امکان پیگیری پرسش‌ها و ارائه پاسخ‌های ساختاریافته را فراهم می‌آورند. در این فضا، هر کاربر می‌تواند هم‌زمان در نقش پرسشگر و پاسخ‌دهنده ظاهر شود که همین تنوع نقش‌ها، به پویایی شبکه کمک می‌کند. محبوبیت چشمگیر پلتفرم‌هایی مانند Stack-Overflow موجب شده پژوهشگران با رویکردی میان‌رشته‌ای به تحلیل محتوایی و ساختاری این سامانه‌ها بپردازند. همچنین کاربران می‌توانند به پاسخ و پرسش دیگر کاربران امتیاز داده و مشخص کنند که این پرسش‌وپاسخ تا چه میزان مفید بوده است. در حوزه بازیابی تخصص یا خبره‌یابی نیز به وفور از داده‌های استخراج شده از این انجمن‌ها برای تحلیل، پژوهش و آزمایش راهکارهای مختلف استفاده می‌شود. [۱۰]

۹.۲ جمع‌بندی

در این فصل با معرفی چندین اصطلاح کاربردی برای ادامه مطالعه پایان‌نامه، یک دید کلی به خواننده در موضوع تحقیقاتی خبره‌یابی یا بازیابی تخصص داده شد. در فصل آینده برای تکمیل دید کلی خواننده نسبت به موضوع، به بررسی پژوهش‌های انجام شده در این حوزه پرداخته خواهد شد.

فصل ۳

کارهای مرتبط

۱.۳ مقدمه

در این بخش بیشتر با مفاهیم بازیابی تخصص یا خبره‌یابی آشنا می‌شوید و شناخت نسبی از تحقیقات انجام شده در این حوزه به دست می‌آورید. از طرفی مسئله این پایان‌نامه در واقع یک مسئله پیش‌بینی سری‌های زمانی^۱ است، پس آخرین فعالیت‌های انجام شده در این حوزه با تمرکز بر کاربرد یادگیری ماشین در پیش‌بینی سری‌های زمانی بررسی خواهد شد.

۲.۳ بازیابی تخصص

به طور کلی حوزه بازیابی تخصص یا خبره‌یابی را می‌توان به دو دسته بزرگ تقسیم کرد، یافتن متخصص^۲ و نمایه‌سازی از تخصص‌های یک متخصص^۳. در بخش یافتن متخصص پژوهشگران تلاش می‌کنند به این سوال پاسخ دهند که، «چه کسانی در موضوع x مهارت دارند؟» هدف کلی این حوزه یافتن متخصص‌ها در مهارت خاص و امتیازدهی به آن‌ها است. از طرف دیگر در دسته نمایه‌سازی تلاش می‌شود که به سوال «فرد x دارای چه مهارت‌هایی است؟» پاسخ دهند. و هدف کلی این دسته یافتن میزان تخصص یک فرد در حوزه‌های مهارتی گوناگون و ساخت نمایه از کاربران است [۴]. مسئله مطرح شده در این پایان‌نامه بیشتر زیرمجموعه نمایه‌سازی قرار می‌گیرد. اما از نتایج آن می‌توان در مسائل یافتن متخصص نیز استفاده کرد.

۱.۲.۳ یافتن متخصص

راه کارهایی که برای مسئله یافتن متخصص مطرح شده را می‌توان به چهار دسته تقسیم کرد. مدل‌های برپایه تجزیه ماتریس، مدل‌های درختی، مدل‌های برپایه یادگیری عمیق و مدل‌های رتبه‌بندی [۱۱][۱۲]. مدل‌های مبتنی بر تجزیه ماتریس یکی از دسته‌های اصلی روش‌های مورد استفاده در سامانه‌های توصیه‌گر و به‌طور خاص در مسئله‌ی یافتن کارشناسان در انجمن‌های پرسش و پاسخ به‌شمار می‌روند. از دیدگاه ریاضی، تجزیه ماتریس به معنای تجزیه‌ی یک ماتریس داده‌شده - که معمولاً تعامل میان کارشناسان و پرسش‌ها را نمایش

^۱ timeseries

^۲ finding Expert

^۳ profiling Expert

می‌دهد - به حاصل ضرب چند ماتریس ساده‌تر و با ابعاد کمتر است. هدف از این فرایند، کشف ویژگی‌های پنهان است که زیربنای روابط میان موجودیت‌هایی مانند کارشناسان و پرسش‌ها را تشکیل می‌دهند. در این چارچوب، هر کارشناس و هر پرسش به فضایی مشترک از عوامل پنهان نگاشته می‌شوند و تعامل میان آن‌ها به صورت ضرب داخلی در این فضا مدل‌سازی می‌شود. این مدل‌ها با هدف کمینه‌سازی تابع خطای مربعات، سعی در افزایش دقت یافتن متخصص دارند [۱۳][۱۴][۱۵][۱۶].

مدل‌های درخت تقویتی نیز به عنوان یکی از روش‌های یادگیری ماشینی برای یافتن متخصص در سامانه‌های پرسش و پاسخ مطرح شده‌اند. در این روش‌ها، پیش‌بینی نهایی با جمع کردن تدریجی چند درخت تصمیم به دست می‌آید مدل‌های مبتنی بر یادگیری عمیق، دسته‌ای برجسته از تکنیک‌ها را در فرایند یافتن متخصص در سامانه‌های پرسش و پاسخ اجتماعی تشکیل می‌دهند؛ این مدل‌ها با یادگیری بازنمایی‌های با ابعاد بالا از اطلاعات متخصصان، اطلاعات موضوع و تعاملات میان آن دو، عملکرد چشمگیری در سامانه‌های پیشنهاددهی و وظایف تطبیق نشان داده‌اند [۱۲].

روش رتبه‌بندی تلاش می‌کند با استفاده از راهکارهای گوناگون از جمله روش‌های آماری یا روش‌های مبتنی بر یادگیری ماشین و با رتبه‌بندی کاندیدها بهترین افراد را برای یک مهارت خاص پیدا کند [۱۱]. از کارهای انجام شده در این حوزه می‌توان به مقاله نشاطی و همکاران اشاره کرد که با استفاده از الگوریتم svm سعی در رتبه‌بندی کاندیدهای یک مهارت دارد [۱۷]. همچنین در مقاله‌ای به قلم رستمی و همکاران تلاش شده که با تمرکز بر یافتن کارآموز برای مهارت‌های خاص روش‌های نوینی در حوزه یافتن تخصص معرفی کند [۱۸].

در پژوهش‌های دیگر تلاش شده به جای یافتن متخصص در حوزه مهارتی خاص، با رتبه‌بندی افراد، فرد مناسب برای حضور در یک تیم چابک را شناسایی و معرفی کند [۱۹][۲۰]. همچنین در پژوهش‌های دیگری که تمرکز آن‌ها به جای یافتن یک فرد متخصص، تلاش برای سازمان‌دهی و جمع‌آوری یک تیم از خبره‌ها بوده است، تلاش شده به جای یافتن یک متخصص یا خبره یک گروه حداقلی از متخصصین شناسایی شود که توانایی انجام یک کار چندجانبه را دارا هستند [۲۱].

در حوزه‌ی تشکیل تیم‌های نرم‌افزاری چابک، پژوهش رستمی به مسئله‌ی شناسایی و انتخاب کارشناسان خبره، به‌ویژه کارشناسان t-shaped که دارای دانش عمیق در یک حوزه‌ی تخصصی و دانش عمومی در چند حوزه‌ی

مرتبط هستند، پرداخته است. نویسندگان این پژوهش محدودیت‌های روش‌های موجود را شناسایی کرده‌اند؛ از جمله تکیه بر مدل‌های غیر یادگیری ماشین مبتنی بر قواعد اکتشافی و استفاده‌ی محدود از صرفاً تعداد اسناد کاربران به جای تحلیل محتوای آن‌ها برای برآورد دانش t-shaped. برای رفع این مشکلات، رویکردی چندمرحله‌ای ارائه شده است که در گام نخست با بهره‌گیری از مدل پیشرفته‌ی RDM، فهرست اولیه‌ی نامزدهای خبره انتخاب می‌شود، سپس با استفاده از یک مدل یادگیری عمیق نوآورانه که محتوای پست‌های کاربران در StackOverflow را تحلیل می‌کند، میزان دانش مرتبط آن‌ها مجدداً برآورد می‌شود و در نهایت، اعضای بهینه‌ی تیم با استفاده از مدل برنامه‌ریزی خطی صحیح انتخاب می‌گردند [۲۲].

در مقاله مروری که در سال ۲۰۲۵ منتشر شده دسته‌بندی جدیدی برای راه‌حل‌های معرفی شده در مسئله یافتن متخصص معرفی شده، که این دسته‌بندی‌ها شامل روش‌های مبتنی بر محتوا، روش‌های مبتنی بر شبکه و روش‌های ترکیبی است. در روش‌های مبتنی بر متن تمرکز روی یافتن متخصص از روی متن تولید شده در وبسایت‌های پرسش و پاسخ است. همچنین در روش‌های مبتنی بر شبکه تمرکز روی یافتن متخصص از طریق ارتباط آن فرد با متخصص‌های از پیش شناخته شده است، و در روش ترکیبی سعی شده که با ادغام دو روش فوق به دقت بالاتری در مسئله یافتن متخصص دست یافت [۲۳].

از کارهایی که در زمینه استفاده از یادگیری ماشین به خصوص یادگیری عمیق در زمینه پیش‌بینی تخصص حال حاضر افراد انجام شده، می‌توان به مقاله، Flambeau Florentin Kameni Jiechieu اشاره کرد. تمرکز این مقاله بر روی تکنیک‌های یادگیری ماشین به جهت پیش‌بینی میزان تخصص افراد بر اساس رزومه آن‌هاست. در واقع در این مقاله بخش‌هایی از تخصص‌های فرد که در رزومه به صورت مستقیم به آن اشاره نشده است، پیش‌بینی می‌شود و سایر بخش‌های نامفهوم تخصص افراد را کشف می‌کند [۲۴].

در حوزه‌ی یافتن متخصص، یکی از چالش‌های اساسی شناسایی کاربران خبره‌ای است که دانش و مهارت لازم برای پاسخ‌گویی به پرسش‌های خاص را داشته باشند؛ زیرا تعداد این افراد معمولاً کمتر از تعداد پرسش‌گران است. برای حل این مسئله‌ی مهم در یافتن کارشناسان و مسیریابی پرسش، قاسمی چارچوبی پیشنهاد کرده‌اند که هم‌زمان از شباهت‌های واژگانی و معنایی بین پرسش‌های جدید و پاسخ‌های موجود، به همراه روابط اجتماعی میان کاربران استفاده می‌کند. این مدل بر پایه‌ی رویکرد مبتنی بر سند که پیش‌تر در یافتن کارشناسان نتایج

امیدوارکننده‌ای نشان داده است، بنا شده و یک معیار شباهت کاربر نیز به آن افزوده شده است تا نامزدها بر اساس حوزه‌های علاقه‌مندی رتبه‌بندی شوند. روش کار شامل ایجاد یک گراف همگن از کاربران سامانه بر اساس گراف چهاروجهی شامل پرسش‌گر، پرسش، پاسخ و پاسخ‌دهنده است که در آن گره‌ها کاربران و یال‌ها زمانی ایجاد می‌شوند که یک کاربر به پرسش کاربر دیگری پاسخ دهد. [۲۵]

همچنین روش‌های دیگری برپایه ساخت یک شبکه همکاری از افراد خبره و یافتن خبره مناسب بر اساس همکاری‌های انجام شده توسط آن خبره با دیگر خبره‌ها معرفی شده و روشی معرفی شده که متخصصان در حیطه کاری مرتبط به هم شناسایی شوند. این روش با استفاده از داده‌های همکاری‌های انجام شده در فعالیت‌های پژوهشی (مثلاً همکاری چند پژوهشگر در انتشار یک مقاله با موضوع خاص) سعی در طراحی و تولید این شبکه همکاری دارد [۲۶]، [۲۷].

از دیگر کارهایی که در حوزه یافتن متخصص پژوهشگر انجام شده می‌توان به مقاله almuhana و yafooz اشاره کرد. در این مقاله با استفاده از منابعی مانند مقالات علمی، استنادات، و اطلاعات نویسندگان تلاش کرده‌اند معیارهایی کمی و کیفی برای سنجش تخصص پژوهشگران ارائه دهند. رویکردهای مختلفی همچون روش‌های مبتنی بر محتوا، تحلیل شبکه‌های اجتماعی علمی و مدل‌های یادگیری ماشین برای رتبه‌بندی و شناسایی متخصصان به کار گرفته شده است [۲۸].

فصل ۴

نتیجه‌گیری و کارهای آینده

ایده و محدوده کاری آینده

در این موضوع با تحلیل داده های خوشه بندی شده ابتدا یک نمایه از هر کاربر که در فرم های اینترنتی مرتبط فعالیت داشته، ساخته میشود. این نمایه توصیف میکند که چند درصد فعالیت کاری هر کاربر به یک موضوع خاص اختصاص داده شده است. سپس یک روش ارزیابی برای امتیازدهی به میزان دقت روش پیشبینی معرفی میشود. به طور کلی سوالی که مطرح میشود و این مقاله سعی در پاسخ دهی به آن دارد این است که بهترین مدل برای پیشبینی تخصص آینده افراد چه مدلی میباشد. این مدل از میان مدل های یادگیری ماشین یا مدل های آماری انتخاب میشود. برای رسیدن به بهترین مدل ابتدا یک روش مناسب برای ارزیابی دقت مدل معرفی میشود. این روش ارزیابی از میان روش های موجود که چند نمونه آن پیشتر مطرح شد انتخاب میشود. سپس چند مدل کاندید انتخاب شده و پیاده سازی آن انجام خواهد شد و نتیجه خروجی آن توسط روش ارزیابی بررسی میشود و بهترین مدل یا چند مدل برتر نسبت به باقی مدل ها معرفی میشود. پس میتوان خروجی این مقاله را یک مدل معرفی شده در نظر گرفت.

تمام مدل ها با نمونه ای از داده های سایت stackoverflow آزمون خواهند شد و پیاده سازی هر مدل انجام میشود. در نتیجه میتوان یک مقایسه میان نتیجه پیشبینی مدل ها روی یک داده ی آزمون انجام داد و از آنجایی که این مقایسه در شرایط برابر میان تمام مدل ها انجام میشود، میتوان نتیجه ارزیابی آن را معتبر در نظر گرفت. این مقایسه از آنجایی دارای اهمیت است که در صورت یافتن بهترین مدل برای پیشبینی این نوع از داده ها در مرحله اول میتوان از آن مدل در کنار کارهایی که پیشتر انجام شده است، روشی معرفی کرد که نتیجه دقیق تری برای جذب افراد در کسب و کارها استفاده کرد در مرحله دوم از نتیجه داده های تولید شده در این مطالعه برای مطالعه های آینده استفاده شود.

همچنین کارهایی که در آینده میتوان در ادامه این کار انجام داد شامل معرفی روشی که پیاده سازی این مدل را برای صنعت راحت تر کند و همچنین افزودن متغیر های جدید به مدل آموزش دیده شده برای یافتن نتیجه دقیق تر میباشد.

نتیجه گیری

به طور کلی مسئله بازیابی نیروی متخصص یک مسئله نسبتاً جدید در حوزه بازیابی اطلاعات میباشد. از این رو مسائل باز زیادی همچنان در این حوزه وجود دارد. این مسائل باز بیشتر در حوزه تحلیل داده های استخراج شده، خوشه بندی آن ها و نتیجه گیری از آن ها برای یافتن بهترین کاندید یک موقعیت شغلی میباشد. ضعف اصلی روش های موجود این است که این است که این روش ها معمولاً پارامترهای کمی را برای بررسی داده های استفاده میکنند و در نتیجه آن خروجی حاصل ممکن است با واقعیت تفاوت داشته باشد. در سال های اخیر سعی شده با معرفی روش هایی دقت خوشه بندی و تحلیل این داده ها افزایش یابد. این مطلب نیز سعی در افزایش دقت روش های پیشین با معرفی روشی جدید برای پیشبینی تخصص آینده افراد دارد تا دقت بازیابی تخصص افراد را افزایش دهد.

کتاب نامه

- [1] M. Kobayashi and K. Takeda, "Information retrieval on the web," *ACM Comput. Surv.*, vol.32, pp.144-173, June 2000. Place: New York, NY, USA Publisher: Association for Computing Machinery.
- [2] M. R. Ghorab, D. Zhou, A. O'Connor, and V. Wade, "Personalised Information Retrieval: survey and classification," *User Modeling and User-Adapted Interaction*, vol.23, pp.381-443, Sept. 2013.
- [3] M. Mitra and B. Chaudhuri, "Information Retrieval from Documents: A Survey," *Information Retrieval*, vol.2, pp.141-163, May 2000.
- [4] K. Balog, Y. Fang, M. de Rijke, P. Serdyukov, and L. Si, "Expertise Retrieval," *Foundations and Trends in Information Retrieval*, vol.6, no.2-3, pp.127-256, 2012.
- [5] M. Diaz and A. D. Smith, "What Makes An Expert? Reviewing How ML Researchers Define Expert", in *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, vol.7, pp.358-370, 2024.
- [6] C. M. Bishop. *Pattern Recognition and Machine Learning* (Information Science and Statistics). Berlin, Heidelberg: Springer-Verlag, 2006.
- [7] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.
- [8] M. Nielsen. *Neural Networks and Deep Learning*. Determination Press, 2015.
- [9] G. Kirchg ssner, J. Wolters, and U. Hassler. *Introduction to modern time series analysis*. Springer Science & Business Media, 2012.
- [10] M. Neshati, "On early detection of high voted Q&A on Stack Overflow," *Information Processing & Management*, vol.53, pp.780-798, July 2017.
- [11] S. Lin, W. Hong, D. Wang, and T. Li, "A survey on expert finding techniques," *Journal of Intelligent Information Systems*, vol.49, pp.255-279, Oct. 2017.
- [12] S. Yuan, Y. Zhang, J. Tang, W. Hall, and J. B. Cabota, "Expert finding in community question answering: a review," *Artificial Intelligence Review*, vol.53, pp.843-874, Feb. 2020.

- [13] S. Rendle, "Factorization Machines," in *2010 IEEE International Conference on Data Mining*, pp.995-1000, 2010.
- [14] K. Hofmann, K. Balog, T. Bogers, and M. de Rijke, "Contextual factors for finding similar experts," *Journal of the American Society for Information Science and Technology*, vol.61, no.5, pp.994-1014, 2010.
- [15] Y. Koren, "Factorization meets the neighborhood: a multifaceted collaborative filtering model," in *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '08, (New York, NY, USA), pp.426-434, Association for Computing Machinery, 2008. event-place : Las Vegas, Nevada, USA.
- [16] X. Chen and L. Sun, "Bayesian temporal factorization for multidimensional time series prediction," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol.44, no.9, pp.4659-4673, 2021.
- [17] M. Neshati, Z. Fallahnejad, and H. Beigy, "On dynamicity of expert finding in community question answering," *Information Processing & Management*, vol.53, Sept. 2017.
- [18] P. Rostami and M. Neshati, "Intern retrieval from community question answering websites : A new variation of expert finding problem," *Expert Systems with Applications*, vol.181, Nov. 2021.
- [19] P. Rostami and M. Neshati, "T-shaped grouping: Expert finding models to agile software teams retrieval," *Expert Systems with Applications*, vol.118, pp.303-308, Mar. 2019.

واژه‌نامه انگلیسی به فارسی

Word کلمه ۱
Word 2 کلمه ۲
Word 3 کلمه ۳

واژه‌نامه فارسی به انگلیسی

word 1		کلمه ۱
word 2		کلمه ۲
word 3		کلمه ۳

Abstract:

This is Abstract in English.

Keywords: Word1, Word2, Word3



Shahid Beheshti University

Faculty of Computer Science & Engineering

Semantic Matching Methods on Object Retrieval

By

Arash Dargahi Nobari

A THESIS SUBMITTED
FOR THE DEGREE OF
MASTER OF SCIENCE

Supervisor :

Dr. Mahmood Neshati

2019