



دانشگاه شهید بهشتی

دانشکده مهندسی و علوم کامپیوتر

راه کاری مبتنی بر یادگیری ماشین برای پیش بینی مهارت های افراد در آینده در وبسایت های پرسش و پاسخ اجتماعی

پایان نامه کارشناسی ارشد مهندسی کامپیوتر
گرایش نرم افزار

نگارش

سینا محمدی

استاد راهنما

دکتر محمود نشاطی

تابستان ۱۴۰۴



دانشگاه شهید بهشتی
دانشکده مهندسی و علوم کامپیوتر

پایان نامه کارشناسی ارشد مهندسی کامپیوتر - گرایش نرم افزار
تحت عنوان:

راه کاری مبتنی بر یادگیری ماشین برای پیش بینی مهارت های افراد در آینده در وبسایت های
پرسش و پاسخ اجتماعی

در تاریخ
پایان نامه دانشجو، سینا محمدی، توسط کمیته تخصصی داوران مورد بررسی و تصویب نهایی قرار
گرفت.

امضا	نام و نام خانوادگی	۱- استاد راهنما اول:
امضا	نام و نام خانوادگی	۲- استاد راهنما دوم:
امضا	نام و نام خانوادگی	۳- استاد مشاور:
امضا	نام و نام خانوادگی	۴- استاد داور (داخلی):
امضا	نام و نام خانوادگی	۵- استاد داور (خارجی):
امضا	نام و نام خانوادگی	۶- نماینده تحصیلات تکمیلی:

کلیه حقوق مادی مترتب بر نتایج مطالعات،
ابتکارات و نوآوری‌های ناشی از تحقیق موضوع
این پایان‌نامه متعلق به دانشگاه شهید بهشتی
می‌باشد.

به نام خدا

نام و نام خانوادگی: سينا محمدی

عنوان پایان نامه: راه کاری مبتنی بر یادگیری ماشین برای پیش بینی مهارت های افراد در آینده در وبسایت های

پرسش و پاسخ اجتماعی

استاد راهنما: دکتر محمود نشاطی

اینجانب سينا محمدی تهیه کننده پایان نامه کارشناسی ارشد حاضر، خود را ملزم به حفظ امانت داری و قدردانی از زحمات سایر محققین و نویسندگان بنابر قانون Copyright می دانم. بدین وسیله اعلام می نمایم که مسئولیت کلیه مطالب درج شده با اینجانب می باشد و در صورت استفاده از اشکال، جداول و مطالب سایر منابع، بلافاصله مرجع آن ذکر شده و سایر مطالب از کار تحقیقاتی اینجانب استخراج گشته است و امانت داری را به صورت کامل رعایت نموده ام. در صورتی که خلاف این مطلب ثابت شود، مسئولیت کلیه عواقب قانونی با شخص اینجانب می باشد.

نام و نام خانوادگی: سينا محمدی

تاریخ و امضا:

چکیده

در عصر تحول دیجیتال، شناسایی تخصص افراد برای سازمان‌ها حیاتی است، اما رویکردهای موجود در حوزه بازیابی تخصص، ماهیتی ایستا و گذشته‌نگر دارند و تنها به این پرسش پاسخ می‌دهند که «چه کسی اکنون متخصص است؟». این مدل‌ها، پویایی و تکامل مهارت‌ها را نادیده گرفته و در نتیجه برای برنامه‌ریزی‌های استراتژیک و بلندمدت، مانند تشکیل تیم برای پروژه‌های آینده، ناکارآمد هستند. این پژوهش با هدف پر کردن این شکاف، برای نخستین بار مسئله‌ی پیش‌بینی تخصص‌های آینده‌ی افراد را به عنوان یک وظیفه‌ی پیش‌بینی سری زمانی چندمتغیره صورت‌بندی می‌کند. با استفاده از داده‌های وب‌سایت StackOverflow، تاریخچه‌ی فعالیت سالانه‌ی کاربران استخراج شده و نمایه‌ی مهارتی آن‌ها به عنوان یک سری زمانی مدل‌سازی می‌شود. یک چالش کلیدی در این مسیر، تعدیل اثر رشد کاربران پلتفرم بر امتیازات است که برای حل آن، یک چارچوب آداپتور نوآورانه مبتنی بر استراتژی‌های نرمال‌سازی متفاوت برای آموزش و ارزیابی مدل ارائه شده است. مدل پیشنهادی که مبتنی بر یک شبکه‌ی عصبی پیشخور است، توانایی خود را در پیش‌بینی نمایه‌ی مهارتی کاربران در سال آینده به اثبات رساند. نتایج ارزیابی با استفاده از معیار شباهت کسینوسی نشان داد که مدل پیشنهادی به دقت ۰.۸۸۲۵ دست یافته است که بهبود چشمگیری نسبت به دقت ۰.۶۴۸۵ در روش پایه دارد. این دستاورد، پارادایم تحلیل تخصص را از توصیف گذشته به پیش‌بینی آینده تغییر داده و ابزاری قدرتمند برای مدیریت استعداد آینده‌نگر و کاهش ریسک در پروژه‌های بلندمدت فراهم می‌آورد.

واژگان کلیدی: بازیابی تخصص، بازیابی اطلاعات، وبسایت‌های پرسش و پاسخ، یادگیری ماشین، سری‌های

زمانی

فهرست مطالب

۱	۱ کلیات
۲	۱.۱ مقدمه
۳	۲.۱ بیان مسئله
۴	۳.۱ اهمیت و ضرورت پژوهش
۵	۴.۱ اهداف و سؤالات پژوهش
۶	۱.۴.۱ اهداف پژوهش
۶	۲.۴.۱ سؤالات پژوهش
۷	۵.۱ کلیات رویکرد پیشنهادی
۸	۶.۱ نوآوری پژوهش
۹	۷.۱ محدوده پژوهش
۹	۸.۱ ساختار پایان نامه
۱۱	۲ ادبیات تحقیق
۱۲	۱.۲ مقدمه
۱۲	۲.۲ بازیابی اطلاعات
۱۳	۳.۲ بازیابی تخصص
۱۴	۴.۲ خبره

۵.۲	یادگیری ماشین	۱۴
۶.۲	یادگیری عمیق	۱۵
۷.۲	سری‌های زمانی	۱۵
۸.۲	انجمن‌های پرسش و پاسخ	۱۶
۹.۲	جمع‌بندی	۱۶

۳ کارهای مرتبط ۱۷

۱.۳	مقدمه	۱۸
۲.۳	بازیابی تخصص	۱۸
۱.۲.۳	یافتن متخصص	۱۹
۲.۲.۳	نمایشه‌سازی	۲۲
۳.۳	پیش‌بینی سری‌های زمانی	۲۴
۴.۳	جمع‌بندی	۲۶

۴ روش پیشنهادی ۲۷

۱.۴	مقدمه	۲۸
۲.۴	تعریف مسئله	۲۸
۱.۲.۴	روش پایه	۲۸
۲.۲.۴	توضیح و تعاریف	۳۰
۳.۴	ساخت مجموعه داده	۳۱
۱.۳.۴	خوشه‌بندی	۳۱
۴.۴	پیش‌پردازش و مهندسی ویژگی	۳۲
۱.۴.۴	بررسی روش‌های نرمال‌سازی	۳۵
۲.۴.۴	تحلیل و دلیل انتخاب روش نهایی	۳۸

۳۹	جدا سازی داده‌های آزمون از داده‌های آموزش مدل	۵.۴
۳۹	انتخاب مدل	۶.۴
۴۰	آموزش مدل	۷.۴
۴۰	چارچوب آداپتور برای پیش‌بینی بین‌مقیاسی	۸.۴
۴۱	خط‌لوله آداپتور	۱۰.۸.۴
۴۲	جمع‌بندی	۲.۸.۴

۵ ارزیابی روش پیشنهادی

۴۵	مقدمه	۱.۵
۴۶	مجموعه داده	۲.۵
۴۶	معیار ارزیابی	۳.۵
۴۷	فرآیند ارزیابی	۴.۵
۴۸	مقایسه دقت	۵.۵
۴۸	جمع‌بندی	۶.۵

۶ نتیجه‌گیری و کارهای آینده

۵۰	مقدمه	۱.۶
۵۱	نتایج کلیدی و تفسیر	۲.۶
۵۱	کارهای آینده	۳.۶
۵۲	انعطاف‌پذیری در مقیاس زمانی	۱.۳.۶
۵۳	یادگیری تقویتی برای افزایش دقت مدل	۲.۳.۶
۵۴	سنجش عمق واقعی دانش با تحلیل محتوای متنی	۳.۳.۶

مراجع

۶۰

واژه‌نامه انگلیسی به فارسی

۶۱

واژه‌نامه فارسی به انگلیسی

فهرست تصاویر

۲۴	دسته‌بندی روش‌های نمایه‌سازی	۱.۳
۲۹	نمودار جریان یک کاربر نمونه	۱.۴
۳۲	حوزه‌های مهارتی تولید شده با استفاده از الگوریتم خوشه‌بندی	۲.۴
۳۵	روند تغییرات مهارتی یک کاربر نمونه	۳.۴
۴۳	مقایسه توزیع داده در روش‌های مختلف نرمال‌سازی	۴.۴
۴۴	رشد کاربران Overflow Stack	۵.۴

فهرست جداول

۱.۴	نام‌گذاری حوزه‌های مهارتی	۳۳
۲.۴	مقایسه روش‌های مختلف نرمال‌سازی	۳۷
۱.۵	مقایسه دقت روش پایه و مدل معرفی شده	۴۹

فصل ۱

کلیات

۱.۱ مقدمه

با تسریع روند نوآوری‌های فناورانه، حفظ مزیت رقابتی سازمان‌ها بیش از گذشته متکی بر دانش تخصصی و ظرفیت‌های شناختی نیروی انسانی شده است. رشد شتابان فناوری و افزایش پیچیدگی پروژه‌ها، جذب و به‌کارگیری افراد خبره را به یکی از اولویت‌های استراتژیک سازمان‌ها تبدیل کرده است. در پاسخ به این نیاز، حوزه‌ای پژوهشی در تقاطع علوم داده و بازایی اطلاعات پدید آمده که با تحلیل مقیاس‌پذیر داده‌های دیجیتال ناشی از کنش‌های کاربران (نظیر مشارکت در انجمن‌های پرسش و پاسخ، مشارکت در پروژه‌های متن‌باز و نشر آثار علمی) به استخراج، سنجش و نمایه‌سازی تخصص افراد می‌پردازد.

اکثر پژوهش‌های پیشین در این حوزه به پرسش «چه کسی در حال حاضر در موضوع X متخصص است؟» متمرکز بوده‌اند. این رویکردها که ماهیتی گذشته‌نگر و ایستا دارند، با اتکا به سوابق تاریخی تصویری از وضعیت کنونی مهارت‌ها ارائه می‌کنند. اگرچه چنین مدل‌هایی برای شناسایی کارشناسان جهت حل مسائل جاری ارزشمندند، اما محدودیتی بنیادین دارند: ناتوانی در مدل‌سازی پویایی تخصص. مهارت‌های فردی ثابت و ایستا نیستند؛ آن‌ها در گذر زمان تکامل می‌یابند، زمینه‌ها و عمق دانش تغییر می‌کند و علاقه‌مندی‌ها ممکن است دگرگون شوند. مدل‌های سنتی قادر به انعکاس این مسیر تکاملی نیستند و بنابراین پاسخ‌گویی به پرسش مهم‌تر «این فرد در آینده در چه زمینه‌هایی متخصص خواهد شد؟» برای آن‌ها دشوار است.

این کاستی پژوهشی به‌ویژه در فرآیندهای برنامه‌ریزی بلندمدت و مدیریت استعداد اهمیت می‌یابد. علاوه بر این، فرآیند جذب، گزینش و آموزش نیروی انسانی برای سازمان‌ها، چه از نظر هزینه‌های مستقیم (نظیر هزینه‌های جذب و دوره‌های آموزشی) و چه از نظر هزینه‌های غیرمستقیم (نظیر اتلاف زمان مدیریت، کاهش موقتی بهره‌وری و هزینه جایگزینی در صورت اشتباه در گزینش)، بار مالی و عملیاتی قابل توجهی ایجاد می‌کند؛ از این‌رو کاهش ریسک‌های ناشی از انتخاب نامناسب نیروی انسانی از اهمیت ویژه‌ای برخوردار است. به‌عنوان مثال، در طراحی تیم برای یک پروژه چندساله، تکیه صرف بر تخصص‌های فعلی کارکنان ممکن است به گزینش نامناسبی منجر شود؛ زیرا نیازهای فناوری پروژه در طول زمان تغییر خواهد کرد. انتخاب بهینه اعضای تیم باید مبتنی بر هم‌راستایی میان توانمندی‌های فعلی و مسیر رشد آتی افراد باشد تا ریسک‌های استراتژیک کاهش یابد. چنین رویکرد آینده‌نگری، فرآیند جذب و توسعه نیروی انسانی را از یک عمل واکنشی به یک برنامه‌ریزی پیشگیرانه

و استراتژیک تبدیل می‌کند.

پژوهش حاضر با هدف پر کردن این خلأ مفهومی و عملی، چارچوبی مبتنی بر یادگیری ماشین ارائه می‌دهد که «تخصص» را به‌عنوان یک فرآیند زمانی مدل‌سازی می‌کند؛ به این معنا که نمایه مهارتی هر فرد به صورت یک سری زمانی از مهارت‌ها تعریف و دنبال می‌شود. با تحلیل الگوهای تکاملی در سوابق فعالیت‌های دیجیتالی کاربران، هدف این پژوهش توسعه مدلی است که نمایه مهارتی افراد را در بازه‌های زمانی آتی پیش‌بینی کند. چنین مدلی می‌تواند سازمان‌ها را در تصمیم‌گیری‌های جذب، جانشین‌پروری و برنامه‌ریزی توسعه مهارت توانمند سازد و در نتیجه به کاهش هزینه‌های جذب و افزایش بازده سرمایه‌گذاری انسانی کمک کند. خروجی این پایان‌نامه می‌تواند در صورت ادغام با روش‌های پیشین، به معرفی روشی دقیق‌تر برای شناسایی خبرگان و متخصصان منجر شود.

بدین ترتیب، این پژوهش می‌کوشد با تبدیل نگاه ایستا به نگاه زمانی نسبت به تخصص انسانی، ابزارهایی فراهم آورد که تصمیم‌گیری پیش‌بینانه در مدیریت استعداد را تقویت نموده و توانمندی سازمان‌ها در تطابق با نیازهای آتی فناوری افزایش یابد.

۲.۱ بیان مسئله

همان‌طور که در بخش مقدمه اشاره شد، پژوهش‌های پیشین در حوزه‌ی بازبایی تخصص، عمدتاً بر شناسایی وضعیت فعلی مهارت‌های افراد متمرکز بوده‌اند. این رویکردها، علی‌رغم کارایی در کاربردهای کوتاه‌مدت، قادر به پاسخگویی به نیازهای استراتژیک و بلندمدت سازمان‌ها در زمینه مدیریت استعداد و تشکیل تیم نیستند. خلأ اصلی، عدم وجود مدلی است که بتواند مسیر تکامل مهارت‌های یک فرد را در آینده پیش‌بینی کند. مسئله‌ای که این پژوهش به آن می‌پردازد، دقیقاً پر کردن همین خلأ است. به طور مشخص، مسئله‌ی این پژوهش عبارت است از: طراحی و ارزیابی یک مدل یادگیری ماشین که بتواند نمایه‌ی مهارتی آتی یک کاربر را بر اساس تاریخچه‌ی نمایه‌های مهارتی او در یک بازه‌ی زمانی مشخص، پیش‌بینی کند. برای صورت‌بندی دقیق‌تر، این مسئله را می‌توان به عنوان یک وظیفه‌ی پیش‌بینی سری زمانی^۱ تعریف کرد:

^۱ Time-Series Forecasting

- **ورودی مسئله:** مجموعه‌ای از نمایه‌های مهارتی یک کاربر خاص (user u) در یک بازه‌ی زمانی T ساله است. هر نمایه در سال t ، یک بردار است که میزان تخصص کاربر را در مجموعه‌ای از حوزه‌های مهارتی $(s_1, s_2, \dots, s_n)$ نشان می‌دهد. بنابراین، ورودی مدل یک توالی از بردارها به شکل زیر است:

$$[\text{Profile}_{u,t-T+1}, \dots, \text{Profile}_{u,t-1}, \text{Profile}_{u,t}]$$

- **خروجی مسئله:** خروجی مطلوب، یک بردار نمایه‌ی مهارتی پیش‌بینی شده برای همان کاربر در سال آینده $(t+1)$ است. این بردار، تخمینی از میزان تخصص فرد در همان حوزه‌های مهارتی خواهد بود:

$$\text{Predicted_Profile}_{u,t+1}$$

برای مثال، با در دست داشتن داده‌های فعالیت یک کاربر در وبسایت Stack Overflow از سال ۲۰۰۸ تا ۲۰۱۴ و ساختن نمایه‌ی سالانه‌ی مهارت‌های او در این بازه، هدف مدل، پیش‌بینی نمایه‌ی مهارت‌های همان کاربر برای سال ۲۰۱۵ است. این پیش‌بینی به ما نشان می‌دهد که کدام مهارت‌های کاربر احتمالاً رشد خواهند کرد، کدام یک ثابت باقی می‌مانند و کدام یک ممکن است کمرنگ‌تر شوند.

بنابراین، پرسش اصلی پژوهش این است: چگونه می‌توان با مدل‌سازی الگوهای زمانی در تاریخچه‌ی فعالیت‌های یک فرد، نمایه‌ی تخصصی او را برای آینده با دقت قابل قبولی پیش‌بینی کرد؟ پاسخ به این پرسش، راه را برای ایجاد سیستم‌های توصیه‌گر هوشمندتر و فرآیندهای مدیریت منابع انسانی آینده‌نگر هموار می‌سازد.

۳.۱ اهمیت و ضرورت پژوهش

در فضای رقابتی امروز، موفقیت سازمان‌ها بیش از هر چیز به توانایی در پیش‌بینی نیازهای آینده و مدیریت هوشمندانه‌ی منابع (به‌ویژه سرمایه‌های انسانی) وابسته است. پیش‌بینی مسیر رشد مهارت‌ها و تطبیق راهبردهای سازمانی با تغییرات محیطی، نه فقط یک مزیت رقابتی بلکه ضرورتی عملی برای بقا و پیشرفت محسوب می‌شود. پژوهش حاضر از دو منظر کلیدی اهمیت دارد: از دید کاربردی و صنعتی برای تسهیل تصمیم‌گیری‌های نیروی انسانی و از دید علمی و پژوهشی برای توسعه‌ی دانش در حوزه‌ی پیش‌بینی مهارت‌ها و مدیریت استعداد.

از منظر کاربردی، بسیاری از فرآیندهای جذب و شکل‌گیری تیم در سازمان‌ها هنوز واکنشی است؛ یعنی تنها در مواجهه با نیاز فوری، جستجوی منابع انسانی آغاز می‌شود. این رویکرد علاوه بر مصرف بالای زمان و هزینه، ریسک قابل توجهی به پروژه‌های بلندمدت تحمیل می‌کند و پایداری تیم را به مخاطره می‌اندازد. پژوهش حاضر می‌کوشد راه‌حلی ارائه دهد که سازمان‌ها را از مدیریت استعدادهای مقطعی و واکنشی به مدیریت استراتژیک و پیش‌نگر منتقل کند.

با پیش‌بینی مسیر رشد مهارت‌های افراد، سازمان‌ها قادر خواهند بود دید بلندمدت‌تری نسبت به تکامل توانمندی‌های کارکنان خود پیدا کنند و به‌صورت پیش‌دستانه برای نیازهای آتی برنامه‌ریزی کنند؛ این رویکرد به کاهش ریسک پروژه‌ها کمک می‌کند، زیرا انتخاب افراد با مسیر رشد همسو با نقشه‌ی راه پروژه احتمال مواجهه با کمبود مهارت در مراحل بعدی را کاهش می‌دهد و پایداری تیم را تقویت می‌کند. علاوه بر این، نتایج تحقیق می‌تواند مبنایی برای سیستم‌های توصیه‌گر هوشمند فراهم آورد که مسیرهای توسعه‌ی فردی را شخصی‌سازی می‌کنند؛ چنین سیستم‌هایی با معرفی مهارت‌های مناسب برای هر فرد، ضمن افزایش انگیزه، توانمندسازی کارکنان را تسهیل می‌کنند.

در مجموع، این پژوهش نه تنها به سازمان‌ها امکان می‌دهد هزینه‌ها و ریسک‌های مرتبط با جذب نیرو را کاهش دهند، بلکه چارچوبی علمی برای طراحی سیاست‌های توسعه‌ی نیروی انسانی ارائه می‌دهد که می‌تواند اثربخشی منابع انسانی را در مواجهه با چالش‌های آینده افزایش دهد.

۴.۱ اهداف و سؤالات پژوهش

با توجه به مسئله‌ی تعریف‌شده و ضرورتی که برای آن بیان شد، این پژوهش به دنبال دستیابی به مجموعه‌ای از اهداف مشخص است. این اهداف در راستای پاسخگویی به یک پرسش اصلی و چندین پرسش فرعی تدوین شده‌اند که مسیر کلی تحقیق را روشن می‌سازند.

۱.۴.۱ اهداف پژوهش

هدف اصلی این پژوهش، فراتر رفتن از تحلیل‌های ایستا و ارائه‌ی یک مدل پویا برای درک و پیش‌بینی تکامل مهارت‌ها است. اهداف جزئی‌تر برای دستیابی به این مهم به شرح زیر است:

- هدف اصلی: طراحی، پیاده‌سازی و ارزیابی یک مدل مبتنی بر یادگیری ماشین که قادر به پیش‌بینی نمایه‌ی مهارتی آتی افراد بر اساس سری زمانی فعالیت‌های گذشته‌ی آن‌ها باشد.

اهداف فرعی

- معرفی و اعتبارسنجی یک چارچوب ارزیابی مناسب برای سنجش کیفیت و دقت نمایه‌های پیش‌بینی شده.
- یافتن یک معماری و روش پیاده‌سازی کارآمد با استفاده از تکنیک‌های یادگیری ماشین که بتواند الگوهای پیچیده‌ی زمانی در داده‌های مهارتی را بیاموزد.
- بررسی چالش‌های مرتبط با کاربران کم‌فعالیت (نمایه‌های با داده‌ی کم) و شناسایی راهکارهای بالقوه برای بهبود پیش‌بینی در این موارد.

۲.۴.۱ سؤالات پژوهش

برای دستیابی به اهداف فوق، این پژوهش تلاش می‌کند تا به سؤالات زیر پاسخ دهد:

سؤال اصلی

- چگونه می‌توان با داشتن نمایه‌ی یک فرد در طول زمان، تغییرات آتی مهارت‌های او را پیش‌بینی کرد؟

سؤالات فرعی

- روش مناسب برای ارزیابی پیش‌بینی تخصص آینده‌ی افراد چه روشی است و مدل پیشنهادی تا چه اندازه دقیق است؟
- بهترین راه برای پیاده‌سازی پیش‌بینی تخصص آینده‌ی افراد با استفاده از روش‌های یادگیری ماشین چیست؟

- چه راهکاری برای پیش‌بینی مهارت‌های کاربرانی که حجم داده‌ی کمی در نمایه‌ی خود دارند، وجود دارد؟

۵.۱ کلیات رویکرد پیشنهادی

برای پاسخگویی به سؤالات مطرح‌شده و دستیابی به اهداف پژوهش، یک رویکرد کمی مبتنی بر یادگیری ماشین اتخاذ می‌شود. چارچوب کلی این پژوهش بر پایه‌ی مدل‌سازی تکامل مهارت‌های هر کاربر به عنوان یک مسئله‌ی پیش‌بینی سری زمانی استوار است. در این دیدگاه، نمایه‌ی مهارتی یک فرد در طول زمان به عنوان یک دنباله‌ی پویا در نظر گرفته می‌شود که می‌توان الگوهای آن را برای پیش‌بینی وضعیت آینده آموخت.

این رویکرد با گردآوری و پردازش داده‌های خام از انجمن پرسش‌وپاسخ StackOverflow آغاز می‌شود. در این مرحله، فعالیت‌های هر کاربر شامل پرسش‌ها، پاسخ‌ها و امتیازات دریافتی در یک بازه‌ی زمانی چندساله استخراج شده و سپس با استفاده از تکنیک‌های خوشه‌بندی، حوزه‌های مهارتی اصلی تعریف می‌گردند. در نهایت، داده‌های تجمیع‌شده به صورت سالانه برای هر فرد یک سری زمانی از نمایه‌های مهارتی را تشکیل می‌دهد. پس از آماده‌سازی داده‌ها، یک مدل یادگیری عمیق مبتنی بر شبکه‌های عصبی طراحی می‌شود که وظیفه‌ی آن، دریافت توالی نمایه‌های گذشته به عنوان ورودی و تولید نمایه‌ی مهارتی سال آینده به عنوان خروجی است. در این فرآیند، توجه ویژه‌ای به نرمال‌سازی داده‌ها برای کنترل اثرات ناشی از رشد جامعه‌ی کاربران و تغییر مقیاس امتیازات در طول زمان خواهد شد. برای سنجش عملکرد نهایی، یک چارچوب ارزیابی دقیق به کار گرفته می‌شود که در آن، عملکرد مدل پیشنهادی در مقایسه با یک روش پایه‌ی ساده (مانند میانگین سال‌های گذشته) و با استفاده از معیار شباهت کسینوسی^۱ ارزیابی می‌گردد. این معیار، تطابق ساختاری بین نمایه‌ی واقعی و پیش‌بینی‌شده را به خوبی اندازه‌گیری می‌کند. این فرآیند یکپارچه، مسیری ساختاریافته را برای پاسخگویی تجربی به سؤالات پژوهش فراهم می‌آورد.

^۱ Similarity Cosine

۶.۱ نوآوری پژوهش

نوآوری اصلی این پژوهش در سه سطح مفهومی، روش‌شناختی و کاربردی قابل تعریف است، اما بنیاد تمام این نوآوری‌ها در یک تغییر پارادایم اساسی نهفته است: حرکت از تحلیلی گذشته‌نگر به مدلی آینده‌نگر.

تغییر پارادایم از توصیف گذشته به پیش‌بینی آینده

مهم‌ترین و بنیادی‌ترین نوآوری این تحقیق، تغییر ماهیت پرسش اصلی در حوزه‌ی بازیابی تخصص است. پژوهش‌های پیشین همواره به دنبال پاسخ به این سؤال بوده‌اند که «یک فرد بر اساس فعالیت‌های گذشته‌اش، اکنون چه تخصص‌هایی دارد؟». این دیدگاه، ماهیتی توصیفی و گذشته‌نگر^۱ دارد. در مقابل، این پژوهش برای نخستین بار پرسش را به «یک فرد بر اساس روند فعالیت‌های گذشته‌اش، در آینده چه تخصص‌هایی خواهد داشت؟» تغییر می‌دهد. این رویکرد ذاتاً پیش‌بینانه و آینده‌نگر^۲ است و حوزه‌ی تحلیل تخصص را از یک ابزار گزارش‌دهی به یک ابزار برنامه‌ریزی استراتژیک ارتقا می‌دهد.

صورت‌بندی مسئله به عنوان پیش‌بینی سری زمانی

در راستای همین تغییر پارادایم، این پژوهش برای اولین بار، نمایه‌ی مهارتی یک کاربر را نه به عنوان یک بردار ایستا، بلکه به عنوان یک سری زمانی پویا و چندمتغیره صورت‌بندی می‌کند. این چارچوب‌بندی جدید اجازه می‌دهد تا از مجموعه ابزارها و مدل‌های قدرتمند تحلیل سری‌های زمانی برای مدل‌سازی تکامل مهارت‌ها استفاده شود. این در حالی است که کارهای پیشین، بُعد زمانی را عمدتاً برای وزن‌دهی به فعالیت‌های اخیر نادیده گرفته و آن را به عنوان محور اصلی برای پیش‌بینی آینده به کار نبرده‌اند.

ارائه راهکار برای تعدیل اثر رشد پلتفرم

یکی دیگر از نوآوری‌های روش‌شناختی این پژوهش، شناسایی و ارائه‌ی راهکار برای یکی از چالش‌های کلیدی در تحلیل داده‌های طولی وب‌سایت‌های اجتماعی است. امتیازات و فعالیت‌ها در این پلتفرم‌ها تحت تأثیر رشد

^۱ Retrospective

^۲ Prospective

کلی تعداد کاربران در طول زمان قرار دارند. این پژوهش با بررسی روش‌های مختلف نرمال‌سازی و ارائه‌ی یک چارچوب آداپتور، راهکاری عملی برای جداسازی مهارت واقعی کاربر از این سوگیری زمانی ارائه می‌دهد که به افزایش دقت و اعتبار مدل پیش‌بینی‌کننده منجر می‌شود.

در مجموع، این پژوهش با تغییر نگاه از گذشته به آینده، معرفی یک صورت‌بندی ریاضیاتی نوین برای مسئله و حل یک چالش فنی مهم، گامی نو در مسیر تکامل حوزه‌ی بازیابی تخصص برمی‌دارد.

۷.۱ محدوده پژوهش

قلمرو این پژوهش به طور دقیق مشخص شده تا عمق و اعتبار نتایج آن تضمین گردد. این تحقیق در حوزه‌ی کلی بازیابی تخصص قرار می‌گیرد، اما با اتخاذ یک رویکرد آینده‌نگر، به طور خاص بر زیرشاخه‌ی جدید «پیش‌بینی تکامل مهارت‌ها» متمرکز است و برخلاف رویکردهای سنتی، به دنبال ارزیابی وضعیت فعلی تخصص افراد نیست، بلکه هدف آن مدل‌سازی و پیش‌بینی روند آتی آن است. برای تحقق این هدف، پژوهش به طور کامل بر داده‌های استخراج‌شده از وبسایت پرسش‌وپاسخ^۱ StackOverflow استوار است و در میان حوزه‌های مهارتی متنوع، صرفاً بر مهارت‌های مرتبط با «زبان برنامه‌نویسی جاوا و اکوسیستم آن» تمرکز دارد. از منظر روش‌شناختی نیز، رویکرد اتخاذشده کاملاً کمی بوده و تحلیل‌ها بر پایه‌ی فراداده‌های^۱ فعالیت کاربران (مانند امتیازها و تاریخ) انجام می‌شود؛ بنابراین، این تحقیق وارد حوزه‌ی تحلیل کیفی یا معنایی محتوای متنی با استفاده از تکنیک‌های پردازش زبان طبیعی^۲ نمی‌شود. در نتیجه، محدوده‌ی این پژوهش را می‌توان «پیش‌بینی آینده‌ی مهارت‌های مرتبط با جاوا بر اساس تحلیل کمی تاریخچه‌ی فعالیت کاربران در پلتفرم StackOverflow تعریف کرد.

۸.۱ ساختار پایان‌نامه

پژوهش حاضر در شش فصل سازمان‌دهی شده است. در فصل اول، که فصل حاضر است، به بیان کلیات پژوهش پرداخته شد. در این فصل، مقدمه‌ای بر موضوع ارائه گردید، مسئله‌ی اصلی تعریف شد، اهمیت و ضرورت انجام تحقیق تشریح شد و در ادامه، اهداف، سؤالات و نوآوری‌های پژوهش به تفصیل بیان گردید. همچنین یک

^۱ Metadata

^۲ Natural Language Processing (NLP)

نمای کلی از رویکرد پیشنهادی برای حل مسئله ارائه شد.

در فصل دوم، با عنوان ادبیات تحقیق، به بررسی مفاهیم و مبانی نظری مورد نیاز برای درک ادامه پژوهش پرداخته می‌شود. در این فصل، خواننده با مفاهیم کلیدی حوزه‌هایی چون بازیابی اطلاعات، بازیابی تخصص، یادگیری ماشین، یادگیری عمیق، سری‌های زمانی و انجمن‌های پرسش و پاسخ آشنا خواهد شد.

در فصل سوم، به مرور کارهای مرتبط پیشین پرداخته می‌شود. در این فصل، پژوهش‌های انجام‌شده در دو حوزه اصلی «بازیابی تخصص» (شامل یافتن متخصص و نمایه‌سازی) و «پیش‌بینی سری‌های زمانی» به صورت نظام‌مند بررسی و تحلیل می‌شوند تا جایگاه پژوهش حاضر در میان ادبیات علمی موجود مشخص شده و شکاف‌های پژوهشی روشن گردد.

در فصل چهارم، روش پیشنهادی برای پیش‌بینی تخصص به طور کامل تشریح می‌شود. این فصل شامل مراحل دقیق ساخت مجموعه داده از وبسایت استک اورفلو، فرآیند پیش‌پردازش و مهندسی ویژگی، بررسی و انتخاب استراتژی‌های نرمال‌سازی داده‌ها، معرفی معماری مدل یادگیری عمیق و در نهایت، چارچوب آدپتور برای آموزش و ارزیابی مدل است.

در فصل پنجم، نتایج به دست آمده از ارزیابی روش پیشنهادی ارائه و تحلیل می‌شود. در این فصل، مجموعه داده‌ی آزمون، معیارهای ارزیابی و فرآیند اجرای آزمایش‌ها به تفصیل شرح داده شده و عملکرد مدل پیشنهادی به صورت کمی با روش پایه‌ی تعریف‌شده مقایسه و تحلیل می‌گردد.

در نهایت، در فصل ششم به نتیجه‌گیری و ارائه‌ی پیشنهاداتی برای کارهای آینده اختصاص دارد. در این فصل، یافته‌های اصلی پژوهش جمع‌بندی شده، به سؤالات تحقیق پاسخ داده می‌شود و ضمن بیان محدودیت‌های کار، مسیرهای پژوهشی جدیدی برای توسعه و بهبود مدل در آینده پیشنهاد می‌گردد.

فصل ۲

ادبیات تحقیق

۱.۲ مقدمه

در این بخش ضمن آشنایی اولیه با مفاهیم کلی و برخی کلیدواژه‌های استفاده شده در ادامه پایان‌نامه، دید بهتری نسبت به مفاهیم بازیابی اطلاعات، داده‌کاوی و همچنین یادگیری ماشین که در ادامه فصل‌های پایان‌نامه، برای بررسی مسئله مطرح شده در فصل قبل و ارائه راهکار مناسب استفاده می‌شود، کسب خواهید کرد.

۲.۲ بازیابی اطلاعات

بازیابی اطلاعات به طور بنیادی به فرایند یافتن اطلاعات مفید و مرتبط با پرسش کاربر از میان یک مجموعه اسناد اطلاق می‌شود. کاربرد اصلی این فرآیند در موتورهای جست‌وجو، سیستم‌های توصیه‌گر^۱، تحلیل شبکه‌های اجتماعی و موارد از این دست است. این فرایند به دلیل عوامل متعددی ذاتاً چالش‌برانگیز است؛ از جمله این که اطلاعات موجود در پایگاه‌های اسنادی معمولاً ساختارمند نیستند، اسناد در زبان طبیعی و به صورت آزاد نوشته می‌شوند و موضوعات بسیار متنوعی را پوشش می‌دهند. در نتیجه، سیستم‌های سنتی بازیابی اطلاعات بیشتر بر شناسایی اسنادی تمرکز داشته‌اند که احتمال می‌رود حاوی اطلاعات مفید باشند، تا ارائه مستقیم پاسخ به پرسش‌های خاص کاربر. روش کلی در این سیستم‌ها شامل نمایش هر سند و پرسش کاربر به صورت یک بردار ویژگی (مجموعه‌ای از ویژگی‌ها با وزن‌های مرتبط)، محاسبه شباهت میان آن‌ها، و سپس ارائه اسناد دارای بیشترین شباهت به کاربر است. در گذشته، نمایه‌سازی^۲ به صورت دستی و با تخصیص کلیدواژه‌ها انجام می‌شد، اما با افزایش اندازه پایگاه‌های داده این رویکرد ناکارآمد شد و روش‌های خودکار نمایه‌سازی توسعه یافتند. با رشد انفجاری اینترنت و افزایش سریع تعداد کاربران، میزبان‌ها و وبسایت‌ها، نیاز به بازیابی اطلاعات کارآمد در وب به طور چشمگیری افزایش یافت. بررسی‌ها نشان می‌دهد حدود ۸۵ درصد از کاربران اینترنت برای یافتن اطلاعات خاص از موتورهای جست‌جو استفاده می‌کنند. با این حال، همین بررسی‌ها نارضایتی قابل توجهی از عملکرد موتورهای جست‌جوی اولیه گزارش کرده‌اند؛ از جمله سرعت پایین بازیابی، تأخیرهای ارتباطی، و کیفیت پایین نتایج شامل نویز (اطلاعات غیرمرتبط) و پیوندهای معیوب. بازیابی اطلاعات در وب با پیچیدگی‌های جدیدی

^۱ system recommendation

^۲ indexing

همراه بود، زیرا حجم اسناد عمومی در وب به مراتب از پایگاه‌های داده کلاسیک بیشتر بوده و ماهیت پویای وب نمایه‌سازی جامع و مداوم را به یک چالش بزرگ تبدیل کرده است. برای مقابله با این چالش‌ها، مدل‌ها و تکنیک‌های متنوعی توسعه یافته‌اند. در مجموع، بازیابی اطلاعات نقشی حیاتی در دسترسی به داده‌ها در عصر دیجیتال دارد. با وجود موانع موجود، انتظار می‌رود که با بهره‌گیری از فناوری‌های نوین مانند هوش مصنوعی، این حوزه در آینده شاهد تحولات بیشتری باشد [۱][۲][۳].

۳.۲ بازیابی تخصص

بازیابی تخصص، شاخه‌ای از علم اطلاعات است که به شناسایی و رتبه‌بندی افراد بر اساس دانش و مهارت آن‌ها در یک حوزه خاص می‌پردازد. این حوزه به‌ویژه در مدیریت دانش، سیستم‌های توصیه‌گر و تحلیل شبکه‌های اجتماعی اهمیت دارد. هدف اصلی آن، یافتن افرادی است که بتوانند به سؤالات تخصصی پاسخ دهند یا در پروژه‌های پیچیده مشارکت کنند. این فرآیند معمولاً با تحلیل اسناد متنی، مانند مقالات علمی یا پست‌های آنلاین، و گاهی با بررسی روابط حرفه‌ای و اجتماعی افراد انجام می‌شود. برای مثال، در محیط‌های آکادمیک، تعداد استنادها و همکاری‌ها می‌تواند معیاری برای سنجش تخصص باشد. روش‌های بازیابی تخصص به سه دسته اصلی تقسیم می‌شوند: مبتنی بر متن، مبتنی بر شبکه و ترکیبی. روش‌های متنی از تکنیک‌های پردازش زبان طبیعی برای ارزیابی محتوای تولیدشده توسط افراد بهره می‌برند. در مقابل، روش‌های مبتنی بر شبکه بر ساختار روابط، مانند همکاری‌های مشترک یا تعاملات در پلتفرم‌های حرفه‌ای، تمرکز دارند. روش‌های ترکیبی که هر دو جنبه را در نظر می‌گیرند، اغلب دقت بیشتری ارائه می‌دهند. یکی از چالش‌های کلیدی این حوزه، تمایز میان تخصص واقعی و فعالیت‌های صرفاً نمایشی است که ممکن است از حضور پررنگ در شبکه‌های اجتماعی ناشی شود. علاوه بر این، مسائل اخلاقی و حریم خصوصی در استفاده از داده‌های شخصی نیز بحث‌برانگیز است و نیاز به توجه ویژه دارد. کاربردهای بازیابی تخصص شامل پیشنهاد متخصصان در سیستم‌های توصیه‌گر، شناسایی کارشناسان در سازمان‌ها و تقویت همکاری‌ها در جوامع علمی است. به طور کلی، بازیابی تخصص پتانسیل بالایی برای بهبود تصمیم‌گیری و همکاری در محیط‌های مختلف دارد و نیازمند تحقیقات بیشتری است. این بخش از پایان‌نامه تلاش کرده تا دیدگاهی جامع و در عین حال قابل فهم از این حوزه ارائه دهد. امید است که این مرور بتواند راهنمایی

اولیه برای پژوهشگران علاقه‌مند به این موضوع باشد [۴].

۴.۲ خبره

خبره به فردی گفته می‌شود که در یک یا چند حوزه مهارتی مهارت داری دانش عمیق یا تجربه عملی گسترده است. در مسائل بازیابی تخصص یا خبره یابی، خبره به کسی گفته می‌شود که توانایی حل مسائل تخصصی در یک زمینه مشخص را دارا است. با این حال این تعریف دقیقی از خبره نیست و خبره بودن یک فرد می‌تواند یک مسئله کاملاً نسبی باشد. ولی در تحقیقات انجام شده معمولاً به فردی که دارای تحصیلات رسمی، گواهی‌نامه‌های حرفه‌ای، تجربه کاری و تجربه زیسته در یک حوزه مهارتی است و منابع معتبر داده این تجربیات را تایید می‌کنند، خبره گفته می‌شود [۵].

۵.۲ یادگیری ماشین

یادگیری ماشین با هدف فراهم کردن چارچوبی نظری برای فهم ساختارها و الگوهای پنهان در داده‌ها شکل گرفته است. یادگیری ماشین در ساده‌ترین سطح خود شامل الگوریتم‌هایی است که از روی داده‌های برچسب‌خورده یا بدون برچسب قواعدی استخراج می‌کنند تا بتوانند بر اساس آن پیش‌بینی یا تحلیل انجام دهند. در روش‌های نظارت‌شده، مدل‌ها مانند رگرسیون‌های خطی یا درخت‌های تصمیم، رابطه‌ی ورودی و خروجی را از داده‌های آموزشی می‌آموزند و قابلیت تعمیم به داده‌های جدید را به دست می‌آورند. خوشه‌بندی و سایر روش‌های بدون نظارت، امکان کشف گروه‌های همگن داخل داده‌ها را فراهم می‌کنند و در مسائلی که اطلاعات برچسب‌دار محدود است، ابزار ارزشمندی هستند. مفهوم «ویژگی‌سازی» نقش محوری در بهبود کیفیت مدل‌ها دارد؛ انتخاب و تبدیل درست ویژگی‌ها می‌تواند عملکرد نهایی را تا چند برابر ارتقا دهد. چالش مهم «بیش‌برازش» هنگامی رخ می‌دهد که مدل به جای فراگیری ساختار کلی، جزئیات داده‌های آموزشی را حفظ کند که برای کنترل آن از روش‌هایی مانند اعتبارسنجی متقابل و تنظیم منظم استفاده می‌شود. در سال‌های اخیر، رویکردهای درتجمع مانند رندوم فارست و گرادیان بوستینگ به دلیل پایداری و دقت بالا، مورد توجه ویژه پژوهشگران عملی قرار گرفته‌اند. ظهور شبکه‌های عصبی عمیق با معماری‌های لایه‌لایه، قلمرو جدیدی برای حل مسائلی مثل

تشخیص تصویر و پردازش زبان طبیعی گشوده است. یادگیری انتقالی نیز امکان استفاده از دانش مدل‌های از پیش‌آموزش‌دیده را در مسائل با داده‌های محدود فراهم کرده است و به کاهش زمان آموزش کمک می‌کند. بحث تفسیرپذیری مدل‌ها به‌عنوان یک ضرورت اخلاقی و کاربردی مطرح است تا تصمیمات ماشینی قابل اعتماد و قابل توضیح باشند. در نهایت، تلفیق روش‌های کلاسیک و نوین بهترین مسیر برای غلبه بر محدودیت‌های هر رویکرد است و در ادامه فصل‌های پژوهش به بررسی جزئیات این ترکیب‌ها و روش‌های پیاده‌سازی عملی خواهیم پرداخت.

۶.۲ یادگیری عمیق

یادگیری عمیق شاخه‌ای از یادگیری ماشین است که براساس تعریف ارائه شده در کتب مرجع، با استفاده از شبکه‌های عصبی چندلایه سعی می‌کند الگوهای پیچیده و غیریکپوخت در داده‌ها را کشف کند. در این رویکرد، هر لایه از شبکه مسئول استخراج ویژگی‌هایی با سطح انتزاعی متفاوت است و ترکیب این ویژگی‌ها به مدل توانایی فهم روابط غیرخطی را می‌دهد. این روش انعطاف‌پذیری بالاتری نسبت به رویکردهای پایه یادگیری ماشین دارد و در نتیجه امکان پیاده‌سازی راه‌حل برای مسائل پیچیده‌تر و با مشخصه‌های بالاتر را دارا است [۶][۷][۸]. لازم به ذکر است که، در این پایان‌نامه نیز از یک شبکه عصبی چندلایه برای حل مسئله پیش‌بینی تخصص استفاده شده است.

۷.۲ سری‌های زمانی

سری‌های زمانی به عنوان چارچوبی برای تحلیل تغییرات کمی در طول بازه‌های پیوسته زمانی شناخته می‌شوند. در بررسی این داده‌ها، توجه به ساختار درونی، همچون روندهای بلندمدت و نوسانات فصلی، اهمیت ویژه‌ای دارد. ماهیت فرایندهای زمان‌مند می‌تواند ویژگی‌های پویایی و خودهمبستگی پیچیده‌ای را نشان دهد. جداسازی عناصر مختلف یک سری زمانی زمینه را برای شناخت عوامل تأثیرگذار فراهم می‌آورد. داده‌های سری زمانی در حوزه‌های گوناگون علمی، از اقتصاد تا علوم محیطی، کاربرد گسترده‌ای یافته‌اند. بررسی بقای ساختاری و ثبات واریانس در بازه‌های زمانی متفاوت، از جمله چالش‌های تحلیل این سری‌هاست. عامل زمانی به‌عنوان

بُعدی پایه‌ای، فرصت و پیچیدگی تحقیقات تجربی را هم‌زمان افزایش می‌دهد. مطالعات مربوط به تغییر رفتار متغیرها در طول زمان، دیدگاهی دینامیک و واقع‌بینانه ارائه می‌کند. درک توالی‌های زمانی، بنیانی برای تحلیل علّی و تبیین روابط متغیرها به حساب می‌آید. تحلیل دقیق سری‌های زمانی دیدی منسجم از سفر داده در طول زمان در اختیار پژوهشگر می‌گذارد. [۹]

۸.۲ انجمن‌های پرسش‌وپاسخ

انجمن‌های پرسش‌وپاسخ به عنوان سکویی برای تبادل دانش میان کاربران، امکان پیگیری پرسش‌ها و ارائه پاسخ‌های ساختاریافته را فراهم می‌آورند. در این فضا، هر کاربر می‌تواند هم‌زمان در نقش پرسشگر و پاسخ‌دهنده ظاهر شود که همین تنوع نقش‌ها، به پویایی شبکه کمک می‌کند. محبوبیت چشمگیر پلتفرم‌هایی مانند Stack-Overflow موجب شده پژوهشگران با رویکردی میان‌رشته‌ای به تحلیل محتوایی و ساختاری این سامانه‌ها بپردازند. همچنین کاربران می‌توانند به پاسخ و پرسش دیگر کاربران امتیاز داده و مشخص کنند که این پرسش‌وپاسخ تا چه میزان مفید بوده است. در حوزه بازیابی تخصص یا خبره‌یابی نیز به وفور از داده‌های استخراج شده از این انجمن‌ها برای تحلیل، پژوهش و آزمایش راهکارهای مختلف استفاده می‌شود. [۱۰]

۹.۲ جمع‌بندی

در این فصل با معرفی چندین اصطلاح کاربردی برای ادامه مطالعه پایان‌نامه، یک دید کلی به خواننده در موضوع تحقیقاتی خبره‌یابی یا بازیابی تخصص داده شد. در فصل آینده برای تکمیل دید کلی خواننده نسبت به موضوع، به بررسی پژوهش‌های انجام شده در این حوزه پرداخته خواهد شد.

فصل ۳

کارهای مرتبط

۱.۳ مقدمه

در این فصل، مروری نظام‌مند بر پیشینه‌ی پژوهش در حوزه‌ی بازیابی تخصص و نمایه‌سازی مهارت‌ها ارائه می‌شود. هدف از این فصل روشن‌سازی مفاهیم کلیدی، طبقه‌بندی روش‌ها و نشان‌دادن روند تکامل رویکردها از روش‌های آماری و مبتنی بر متن تا مدل‌های یادگیری عمیق و روش‌های ترکیبی شبکه‌ای است. علاوه بر این، چالش‌ها و محدودیت‌های موجود در هر زیرحوزه (مانند کمبود برچسب‌های زمانی، پراکندگی منابع داده، و نیاز به توازن میان دقت و تبیین‌پذیری) بررسی شده و پیوند میان مسائل یافتن متخصص، نمایه‌سازی فردی و نیاز به مدل‌سازی تغییرات زمانی سطح تخصص برجسته می‌گردد. بخش پایانی این فصل نیز مروری بر روش‌های پیش‌بینی سری‌های زمانی خواهد داشت که برای مدل‌سازی تکامل مهارت‌ها حیاتی‌اند.

ساختار فصل به گونه‌ای تنظیم شده است که ابتدا دسته‌بندی و مروری بر روش‌های یافتن متخصص (شامل مدل‌های ماتریسی، درختی، یادگیری عمیق و روش‌های رتبه‌بندی) ارائه شود، سپس به روش‌های نمایه‌سازی و تکنیک‌های متداول در این زمینه (آماری، مبتنی بر فیلترینگ، همسایگی، یادگیری ماشین و آنتولوژی) پرداخته شود. این مرور ادبیات زمینه‌ی لازم برای فصل‌های بعدی را فراهم می‌آورد و خلاها و فرصت‌های پژوهشی که روش پیشنهادی پایان‌نامه قصد پوشش آن‌ها را دارد، مشخص می‌سازد.

همچنین بخشی از تحقیقات انجام شده در زمینه پیش‌بینی سری‌های زمانی نیز در این فصل بررسی خواهد شد.

۲.۳ بازیابی تخصص

به طور کلی حوزه بازیابی تخصص یا خبره‌یابی را می‌توان به دو دسته کلی تقسیم کرد، یافتن متخصص^۱ و نمایه‌سازی از تخصص‌های یک متخصص^۲. در بخش یافتن متخصص پژوهشگران تلاش می‌کنند به این سوال پاسخ دهند که، «چه کسانی در موضوع x مهارت دارند؟» هدف کلی این حوزه یافتن متخصص‌ها در مهارت خاص و امتیازدهی به آن‌ها است. از طرف دیگر در دسته نمایه‌سازی تلاش می‌شود که به سوال «فرد x دارای

^۱ finding Expert

^۲ profiling Expert

چه مهارت‌هایی است؟» پاسخ دهند. و هدف کلی این دسته یافتن میزان تخصص یک فرد در حوزه‌های مهارتی گوناگون و ساخت نمایه از کاربران است [۴].

طبق دسته‌بندی دیگری که بر اساس مقاله مروری منتشر شده به قلم Dorneles و Gonçalves است، مراحل بازیابی تخصص را می‌توان به چهار دسته کلی تقسیم کرد. این چهار دسته شامل شناسایی منابع داده، استخراج داده، دسته‌بندی و پیش‌پردازش داده‌های استخراج شده و تحلیل داده‌های استخراج است [۱۱]. مسئله مطرح شده در این پایان‌نامه بیشتر زیرمجموعه نمایه‌سازی قرار می‌گیرد. اما از نتایج آن می‌توان در مسائل یافتن متخصص نیز استفاده کرد.

۱.۲.۳ یافتن متخصص

راه کارهایی که برای مسئله یافتن متخصص مطرح شده را می‌توان به چهار دسته تقسیم کرد. مدل‌های برپایه تجزیه ماتریس، مدل‌های درختی، مدل‌های برپایه یادگیری عمیق و مدل‌های رتبه‌بندی [۱۲][۱۳]. مدل‌های مبتنی بر تجزیه ماتریس یکی از دسته‌های اصلی روش‌های مورد استفاده در سامانه‌های توصیه‌گر و به‌طور خاص در مسئله یافتن کارشناسان در انجمن‌های پرسش و پاسخ به‌شمار می‌روند. از دیدگاه ریاضی، تجزیه ماتریس به معنای تجزیه یک ماتریس داده‌شده - که معمولاً تعامل میان کارشناسان و پرسش‌ها را نمایش می‌دهد - به حاصل ضرب چند ماتریس ساده‌تر و با ابعاد کمتر است. هدف از این فرایند، کشف ویژگی‌های پنهان است که زیربنای روابط میان موجودیت‌هایی مانند کارشناسان و پرسش‌ها را تشکیل می‌دهند. در این چارچوب، هر کارشناس و هر پرسش به فضایی مشترک از عوامل پنهان نگاشته می‌شوند و تعامل میان آن‌ها به صورت ضرب داخلی در این فضا مدل‌سازی می‌شود. این مدل‌ها با هدف کمینه‌سازی تابع خطای مربعات، سعی در افزایش دقت یافتن متخصص دارند [۱۴][۱۵][۱۶][۱۷].

مدل‌های درخت تقویتی نیز به عنوان یکی از روش‌های یادگیری ماشینی برای یافتن متخصص در سامانه‌های پرسش و پاسخ مطرح شده‌اند. در این روش‌ها، پیش‌بینی نهایی با جمع کردن تدریجی چند درخت تصمیم به دست می‌آید مدل‌های مبتنی بر یادگیری عمیق، دسته‌ای برجسته از تکنیک‌ها را در فرایند یافتن متخصص در سامانه‌های پرسش و پاسخ اجتماعی تشکیل می‌دهند؛ این مدل‌ها با یادگیری بازنمایی‌های با ابعاد بالا از اطلاعات متخصصان، اطلاعات موضوع و تعاملات میان آن دو، عملکرد چشمگیری در سامانه‌های پیشنهاددهی و وظایف تطبیق نشان

داده‌اند [۱۳].

روش رتبه‌بندی تلاش می‌کند با استفاده از راهکارهای گوناگون از جمله روش‌های آماری یا روش‌های مبتنی بر یادگیری ماشین و با رتبه‌بندی کاندیداها بهترین افراد را برای یک مهارت خاص پیدا کند [۱۲]. از کارهای انجام شده در این حوزه می‌توان به مقاله نشاطی و همکاران اشاره کرد که با استفاده از الگوریتم svm سعی در رتبه‌بندی کاندیداها برای مهارت دارد [۱۸]. همچنین در مقاله‌ای به قلم‌رست می و همکاران تلاش شده که با تمرکز بر یافتن کارآموز برای مهارت‌های خاص روش‌های نوینی در حوزه یافتن تخصص معرفی کند [۱۹].

در پژوهش‌های دیگر تلاش شده به جای یافتن متخصص در حوزه مهارتی خاص، با رتبه‌بندی افراد، فرد مناسب برای حضور در یک تیم چابک را شناسایی و معرفی کند [۲۰][۲۱]. همچنین در پژوهش‌های دیگری که تمرکز آن‌ها به جای یافتن یک فرد متخصص، تلاش برای سازمان‌دهی و جمع‌آوری یک تیم از خبره‌ها بوده است، تلاش شده به جای یافتن یک متخصص یا خبره یک گروه حداقلی از متخصصین شناسایی شود که توانایی انجام یک کار چندجانبه را دارا هستند [۲۲].

در حوزه‌ی تشکیل تیم‌های نرم‌افزاری چابک، پژوهش رست می به مسئله‌ی شناسایی و انتخاب کارشناسان خبره، به‌ویژه کارشناسان t-shaped که دارای دانش عمیق در یک حوزه‌ی تخصصی و دانش عمومی در چند حوزه‌ی مرتبط هستند، پرداخته است. نویسندگان این پژوهش محدودیت‌های روش‌های موجود را شناسایی کرده‌اند؛ از جمله تکیه بر مدل‌های غیر یادگیری ماشین مبتنی بر قواعد اکتشافی و استفاده‌ی محدود از صرفاً تعداد اسناد کاربران به جای تحلیل محتوای آن‌ها برای برآورد دانش t-shaped. برای رفع این مشکلات، رویکردی چندمرحله‌ای ارائه شده است که در گام نخست با بهره‌گیری از مدل پیشرفته‌ی RDM، فهرست اولیه‌ی نامزدهای خبره انتخاب می‌شود، سپس با استفاده از یک مدل یادگیری عمیق نوآورانه که محتوای پست‌های کاربران در StackOverflow را تحلیل می‌کند، میزان دانش مرتبط آن‌ها مجدداً برآورد می‌شود و در نهایت، اعضای بهینه‌ی تیم با استفاده از مدل برنامه‌ریزی خطی صحیح انتخاب می‌گردند [۲۳].

در مقاله مروری که در سال ۲۰۲۵ منتشر شده دسته‌بندی جدیدی برای راه‌حل‌های معرفی شده در مسئله یافتن متخصص معرفی شده، که این دسته‌بندی‌ها شامل روش‌های مبتنی بر محتوا، روش‌های مبتنی بر شبکه و روش‌های ترکیبی است. در روش‌های مبتنی بر متن تمرکز روی یافتن متخصص از روی متن تولید شده در

وبسایت‌های پرسش و پاسخ است. همچنین در روش‌های مبتنی بر شبکه تمرکز روی یافتن متخصص از طریق ارتباط آن فرد با متخصص‌های از پیش شناخته شده است، و در روش ترکیبی سعی شده که با ادغام دو روش فوق به دقت بالاتری در مسئله یافتن متخصص دست یافت [۲۴].

از کارهایی که در زمینه استفاده از یادگیری ماشین به خصوص یادگیری عمیق در زمینه پیش‌بینی تخصص حال حاضر افراد انجام شده، می‌توان به مقاله Flambeau Florentin Kameni Jiechieu اشاره کرد. تمرکز این مقاله بر روی تکنیک‌های یادگیری ماشین به جهت پیش‌بینی میزان تخصص افراد بر اساس رزومه آن‌هاست. در واقع در این مقاله بخش‌هایی از تخصص‌های فرد که در رزومه به صورت مستقیم به آن اشاره نشده است، پیش‌بینی می‌شود و سایر بخش‌های نامفهوم تخصص افراد را کشف می‌کند [۲۵].

در حوزه‌ی یافتن متخصص، یکی از چالش‌های اساسی شناسایی کاربران خبره‌ای است که دانش و مهارت لازم برای پاسخ‌گویی به پرسش‌های خاص را داشته باشند؛ زیرا تعداد این افراد معمولاً کمتر از تعداد پرسش‌گران است. برای حل این مسئله‌ی مهم در یافتن کارشناسان و مسیریابی پرسش، قاسمی چارچوبی پیشنهاد کرده‌اند که هم‌زمان از شباهت‌های واژگانی و معنایی بین پرسش‌های جدید و پاسخ‌های موجود، به همراه روابط اجتماعی میان کاربران استفاده می‌کند. این مدل بر پایه‌ی رویکرد مبتنی بر سند که پیش‌تر در یافتن کارشناسان نتایج امیدوارکننده‌ای نشان داده است، بنا شده و یک معیار شباهت کاربر نیز به آن افزوده شده است تا نامزدها بر اساس حوزه‌های علاقه‌مندی رتبه‌بندی شوند. روش کار شامل ایجاد یک گراف همگن از کاربران سامانه بر اساس گراف چهاروجهی شامل پرسش‌گر، پرسش، پاسخ و پاسخ‌دهنده است که در آن گره‌ها کاربران و یال‌ها زمانی ایجاد می‌شوند که یک کاربر به پرسش کاربر دیگری پاسخ دهد [۲۶].

همچنین روش‌های دیگری بر پایه ساخت یک شبکه همکاری از افراد خبره و یافتن خبره مناسب بر اساس همکاری‌های انجام شده توسط آن خبره با دیگر خبره‌ها معرفی شده و روشی معرفی شده که متخصصان در حیطه کاری مرتبط به هم شناسایی شوند. این روش با استفاده از داده‌های همکاری‌های انجام شده در فعالیت‌های پژوهشی (مثلاً همکاری چند پژوهشگر در انتشار یک مقاله با موضوع خاص) سعی در طراحی و تولید این شبکه همکاری دارد [۲۷].

از دیگر کارهایی که در حوزه یافتن متخصص پژوهشگر انجام شده می‌توان به مقاله almuhana و yafooz اشاره کرد.

در این مقاله با استفاده از منابعی مانند مقالات علمی، استنادات، و اطلاعات نویسندگان تلاش کرده‌اند معیارهایی کمی و کیفی برای سنجش تخصص پژوهشگران ارائه دهند. رویکردهای مختلفی همچون روش‌های مبتنی بر محتوا، تحلیل شبکه‌های اجتماعی علمی و مدل‌های یادگیری ماشین برای رتبه‌بندی و شناسایی متخصصان به کار گرفته شده است [۲۸].

۲.۲.۳ نمایه‌سازی


هدف کلی کارهای این حوزه، پاسخ دادن به این سوال است که یک متخصص چه مهارت‌هایی داشته و دارد. معمولاً این سوال پس از یافتن متخصص و نیاز به بررسی دقیق‌تر تخصص‌های آن فرد پرسیده می‌شود [۲۹]. یک مقاله مروری که در حوزه نمایه‌سازی به دسته‌بندی روش‌های ساخت نمایه می‌پردازد، روش‌های ساخت نمایه کاربران را به پنج دسته کلی تقسیم می‌کند. این روش‌ها شامل روش‌های آماری، روش‌های مبتنی بر یادگیری ماشین، روش‌های مبتنی بر فیلتر کردن اطلاعات کاربر، تکنیک‌های مبتنی بر یافتن همسایگی و روش‌های هستی‌شناسانه است [۳۰]. روش‌های آماری با استفاده از کلمات کلیدی یا لاگ‌های کاربر، یک نمایه کاربری ایجاد می‌کند. در سامانه‌های وب، این کار ممکن است شامل کلمات بسیار پرتکرار در صفحات وب بازدید شده باشد. برای مثال، یک مدل می‌تواند بر اساس توییت‌ها، نشانی‌های اینترنتی مورد علاقه، افراد دنبال شده و رأی‌دهی اجتماعی در میان همسایگی کاربر، آدرس‌های اینترنتی را به کاربران توییت‌ر پیشنهاد دهد. همچنین می‌تواند الگوهای استفاده را از لاگ‌های سامانه‌های رایانه‌ای استخراج کند تا ناهنجاری‌ها را شناسایی نماید، هرچند این امر دامنه تحلیل را به رفتارهای کاربری ثبت شده محدود می‌کند [۳۱]. در روش فیلترینگ با معرفی یک سری قوانین، اطلاعات موجود برای یک کاربر به گونه‌ای فیلتر می‌شود که اطلاعات مورد نیاز باقی‌مانده و اطلاعات غیرمرتبط با کاربر حذف می‌شود، در نهایت یک نمایه باکیفیت از کاربر باقی می‌ماند [۳۲]. استفاده از یادگیری ماشین در نمایه‌سازی در پژوهش‌های متفاوتی معرفی شده، اما به طور کلی در این روش‌ها مدلی معرفی می‌شود که به عنوان ورودی اطلاعات بدون برچسب شامل اطلاعات رزومه، لایک‌ها و دیسلایک‌های دریافت شده در شبکه‌های اجتماعی و غیره دریافت شده و نمایه کاربر به عنوان خروجی مدل معرفی می‌شود [۳۰]. تکنیک مبتنی بر همسایگی رویکردی است که از مفهوم «دنبال کردن دوستان» یا گروه‌هایی از دوستان با علایق مشترک (که به آن همسایگی گفته می‌شود) استفاده می‌کند. هدف اصلی این روش، ایجاد یک فهرست مرتب از کاربران

برای هر کاربر است که اعضای آن از نظر علایق و ویژگی‌ها به کاربر شباهت دارند. این روش می‌تواند با رفع کمبود اطلاعات در نمایش علایق شخصی، به ساخت نمایه کاربر کمک کند و معمولاً برای این کار از تاریخچه مرور کاربر استفاده می‌شود. به عنوان نمونه، از این روش برای تخمین موقعیت مکانی کاربران توییتر در سطح شهر با تحلیل ویژگی‌ها، همبستگی‌ها و روابط برچسب‌خورده در یک شبکه اجتماعی استفاده شده است [۳۳].

در روش مبتنی بر آنتولوژی برای پروفایل‌سازی کاربر، از آنتولوژی‌ها به عنوان یک مفهوم‌سازی از حوزه مورد نظر در قالبی قابل فهم برای انسان و قابل پردازش توسط ماشین استفاده می‌شود که شامل موجودیت‌ها، ویژگی‌ها، روابط و قواعد است. این رویکرد به‌ویژه با پیشرفت وب معنایی^۱، پتانسیل بالایی برای بهبود پروفایل‌سازی کاربر دارد. اهمیت این روش در آن است که چالش‌های مرتبط با اشتراک‌گذاری علایق کاربر - که یکی از مشکلات رایج در نمایش پروفایل کاربر است - را برطرف می‌کند و امکان نمایش مؤثر علایق کاربر و تبادل اطلاعات مرتبط در میان سامانه‌های مختلف را فراهم می‌آورد [۳۴].

از دیگر کارهای انجام شده در زمینه یافتن پروفایل، می‌توان به مقاله دهقان اشاره کرد که تلاش می‌کند با استخراج نمایه افراد t-shaped به سازمان‌ها و شرکت‌ها برای جذب بهتر نیروی انسانی کمک کند [۳۵]. در مطالعه‌ای توسط سیلوا و همکاران رویکردی مبتنی بر گراف برای شناسایی نمایه افراد ارائه شده است. هدف اصلی این پژوهش، استخراج حوزه‌های تخصصی افراد بدون نیاز به برچسب‌گذاری قبلی بوده است؛ این موضوع به‌ویژه برای شناسایی گروه‌های پژوهشی در یک سازمان و بررسی شباهت میان حوزه‌های تخصصی پژوهشگران اهمیت دارد. زیرا با این روش می‌توان با اطلاعات جمع‌آوری شده از منابع مختلف نمایه کامل‌تری از کاربران تولید کرد [۳۶]. در دیگر کارهای انجام شده، روند تغییرات نمایه افراد در طول زمان ساخته شده و این تغییرات با استفاده از نمودارهای مختلف به تصویر کشیده می‌شود [۳۷] [۳۸].

^۱ وب معنایی یا web semantic مفهومی است که توسط تیم برنرز-لی، خالق وب جهان‌گستر، مطرح شد و هدف آن ارتقاء وب موجود به محیطی است که در آن داده‌ها دارای معنا و ساختار مشخص برای ماشین‌ها باشند. در این رویکرد، اطلاعات به گونه‌ای توصیف می‌شوند که نه تنها برای انسان، بلکه برای نرم‌افزارها نیز قابل درک، پردازش و استنتاج باشند.



شکل ۱.۳: نمایش دهنده تکنیک‌های ساخت نمایه به تفکیک و همچنین روش‌های پیاده‌سازی هر تکنیک است [۳۰].

۳.۳ پیش‌بینی سری‌های زمانی

داده‌های سری زمانی، که به‌عنوان مجموعه‌ای از مشاهدات زمانی تعریف می‌شوند، یکی از حوزه‌های برجسته پژوهش در یادگیری ماشین و هوش مصنوعی هستند. این داده‌ها نقش حیاتی در تفسیر پدیده‌های پیچیده دنیای واقعی و شناسایی روندهای آینده ایفا می‌کنند. این مجموعه داده‌ها در حوزه‌های گوناگونی از جمله مدل‌سازی اقلیم، علوم زیستی، پزشکی، خرده‌فروشی و مالی و به‌طور کلی هر حوزه‌ای که بعد زمان در آن مطرح است، به‌طور گسترده‌ای وجود دارند؛ جایی که پیش‌بینی دقیق می‌تواند پایه‌ای برای کاربردهایی مانند برنامه‌ریزی تولید و بهینه‌سازی فراهم کند. تکامل روش‌های پیش‌بینی سری‌های زمانی از رویکردهای آماری کلاسیک به سمت تکنیک‌های یادگیری عمیق پیش رفته است که ناشی از افزایش حجم داده‌ها، ابعاد بالا و پیچیدگی آن‌هاست. از آنجایی که مسئله مطرح شده در این پایان‌نامه به صورت تئوری یک مسئله پیش‌بینی سری‌های زمانی است، لازم است پژوهش‌های انجام شده در این حوزه بررسی شود تا راه‌حل ارائه شده منطبق بر آخرین پیشرفت‌ها در این زمینه باشد.

از پژوهش‌های انجام شده در این زمینه می‌توان به مقاله Liu و همکاران اشاره کرد که در آن روش‌های سنتی سری‌های زمانی مانند مدل خودرگرسیون، میانگین متحرک و مدل تلفیقی به‌عنوان پایه‌ای‌ترین تکنیک‌ها معرفی شده است. در ادامه، با توسعه مدل ARIMA^۱، فصل جدیدی در پیش‌بینی داده‌های غیرایستا گشوده شد تا بتوان نوسانات بلندمدت را دقیق‌تر مدل‌سازی کرد. با ظهور داده‌های حجیم و پیچیده، محققان به سمت روش‌های یادگیری ماشین مثل شبکه‌های عصبی مصنوعی و ماشین بردار پشتیبان^۲ سوق یافتند. سپس، استفاده از شبکه‌های بازگشتی به ویژه شبکه‌های حافظه بلندمدت^۳، امکان یادگیری وابستگی‌های طولانی‌مدت را فراهم ساخت [۳۹].

از دیگر کارهایی که جدای از تکنیک‌های آماری، بر جمع‌آوری و بررسی روش‌های مبتنی بر یادگیری ماشین در پیش‌بینی سری‌های زمانی تمرکز دارند، می‌توان به مقاله محمود و محمد اشاره کرد که روش‌های پارامتریک کلاسیک (از جمله مدل خودرگرسیون، هموارسازی نمایی و مدل‌های ساختاری سری‌های زمانی) را پایه کار خود قرار داده‌اند. این پژوهش نشان می‌دهد که تکنیک‌های یادگیری عمیق، برخاسته از موفقیت‌هایشان در

^۱ مدل ARIMA یا خودرگرسیونی یکپارچه با میانگین متحرک یکی از پرکاربردترین مدل‌های آماری در تحلیل سری‌های زمانی است. این مدل ترکیبی از سه مؤلفه اصلی دارد:

- خودرگرسیونی که از مقادیر گذشته متغیر برای پیش‌بینی مقدار فعلی استفاده می‌کند،
- میانگین متحرک که خطاهای پیشین مدل را در نظر می‌گیرد،
- تفاضل‌گیری که برای ایست کردن سری زمانی به کار می‌رود.

^۲ ماشین بردار پشتیبان یا SVM یکی از الگوریتم‌های قدرتمند یادگیری نظارت‌شده است که برای مسائل طبقه‌بندی و رگرسیون به کار می‌رود.

^۳ شبکه‌های حافظه بلندمدت کوتاه‌مدت یکی از گونه‌های پیشرفته شبکه‌های عصبی بازگشتی هستند که برای مدل‌سازی داده‌های دنباله‌دار مانند سری‌های زمانی، متن و گفتار طراحی شده‌اند. برخلاف شبکه‌های عصبی معمولی که با مشکل ناپدید شدن گرادین مواجه می‌شوند و نمی‌توانند وابستگی‌های بلندمدت را به‌خوبی حفظ کنند، شبکه‌های حافظه بلندمدت با استفاده از ساختاری خاص به‌نام سلول حافظه و سه دروازه (ورودی، خروجی و فراموشی) قادر است اطلاعات مهم را برای بازه‌های زمانی طولانی حفظ کرده و اطلاعات غیرضروری را حذف کند. این ویژگی باعث شده شبکه‌های حافظه بلندمدت در بسیاری از کاربردهای پیش‌بینی سری‌های زمانی، ترجمه ماشینی و تحلیل احساسات عملکرد بسیار موفق‌تری داشته باشد.

دسته‌بندی تصاویر، پردازش زبان طبیعی و یادگیری تقویتی، می‌توانند الگوهای پیچیده زمانی را به خوبی مدل‌سازی کنند. اخیراً، مدل‌های مبتنی بر مکانیزم توجه با توانایی درک روابط بلندمدت در داده‌های ترتیبی و ترکیب آن‌ها با اجزاء آماری کلاسیک در مدل‌های هیبرید، دقت پیش‌بینی را به‌طور چشمگیری ارتقا داده‌اند [۴۰].

در زمینه پیش‌بینی سری‌های زمانی از طریق یادگیری عمیق نیز می‌توان به مقاله Han و همکاران اشاره کرد که پژوهش‌های پیشین را در حوزه پیش‌بینی سری‌های زمانی مرور و تحلیل می‌کند. در این مقاله، مدل‌های کلاسیک مانند ARIMA، روش‌های مبتنی بر فیلترینگ و ماشین‌های بردار پشته‌ای^۱ به‌عنوان پایه‌ای‌ترین تکنیک‌ها معرفی شده‌اند. همچنین شبکه‌های عصبی سطح پایین شامل پرسپترون‌های چندلایه و شبکه‌های بازگشتی سنتی، به همراه مدل‌های مولد مانند فرآیندهای گاوسی و شبکه‌های بیزی بررسی شده‌اند. این روش‌های قدیمی اغلب در مواجهه با داده‌های حجیم و پیچیده ناتوان بودند و محدودیت‌هایی در نمایش کارآمد توابع پیچیده داشتند. مقاله حاضر با به‌کارگیری تکنیک‌های یادگیری عمیق، این خلأها را پر کرده و ظرفیت مدل‌سازی و پیش‌بینی الگوهای چندبعدی و بزرگ را به‌طور چشمگیری ارتقا می‌دهد [۴۱].

۴.۳ جمع‌بندی

در این فصل ضمن آشنایی با حوزه تحقیقاتی بازیابی تخصص یا خبره‌یابی به دو زیربخش یافتن متخصص و نمایه‌سازی پرداخته شد. همچنین بررسی روی تحقیقات انجام شده در حوزه سری‌های زمانی و یادگیری عمیق در این حوزه انجام شد. در فصل آینده روش پیشنهادی برای مسئله پیش‌بینی تخصص معرفی خواهد شد.

^۱ ماشین‌های بردار پشته‌ای نوعی معماری ترکیبی هستند که از چندین مدل ماشین بردار پشتیبان به‌صورت لایه‌ای یا سلسله‌مراتبی استفاده می‌کنند.

فصل ۴

روش پیشنهادی

۱.۴ مقدمه


در این فصل ابتدا در بخش ۲-۴ به بیان مسئله و فرضیات پیرامون آن پرداخته می‌شود. سپس در بخش ۳-۴ و ۴-۴ مراحل جمع‌آوری داده و پیش‌پردازش روی آن معرفی می‌شود. سپس در بخش‌های ۵-۴، ۶-۴ و ۷-۴ فرآیند آموزش مدل معرفی می‌شود. در بخش ۸-۴ نیز چهارچوبی برای آماده‌سازی داده جهت ارزیابی میزان کارایی مدل معرفی شده، معرفی می‌شود.

۲.۴ تعریف مسئله

در مسئله پیش‌بینی تخصص ورودی مسئله روند تغییرات مهارت‌های یک فرد در یک بازه زمانی (مثلاً در این پایان‌نامه از بازه ۲۰۰۸ تا ۲۰۱۴ میلادی استفاده شده است) و خروجی آن میزان خبرگی آن فرد در سال جدید (در این پایان‌نامه سال ۲۰۱۵ میلادی به عنوان سال جدید و سالی که پیش‌بینی خبرگی فرد در آن سال انجام می‌شود در نظر گرفته شده است) است. در واقع در این مسئله نمایه کاربر در یک بازه زمانی چند ساله به عنوان ورودی به مدل معرفی شده داده شده و سپس نمایه آن کاربر در سال جدید توسط مدل پیش‌بینی می‌شود. در شکل ۱.۴ یک کاربر نمونه و میزان تغییرات تخصص‌های این فرد در بازه زمانی توسط یک نمودار جریان نمایش داده شده. هدف اصلی این مسئله پیش‌بینی سال جدید با استفاده از داده‌های سال‌های گذشته است به طوری که بیشتری شباهت را با تخصص‌های واقعی افراد داشته باشد.

۱.۲.۴ روش پایه

از آنجایی که مسئله مطرح شده در واقع یک مسئله پیش‌بینی سری‌های زمانی است، انتخاب و تعریف یک روش پایه اهمیت زیادی دارد، زیرا امکان مقایسه و ارزیابی عملکرد روش‌های پیشنهادی را فراهم می‌سازد. در واقع، روش پایه به عنوان یک معیار حداقلی عمل می‌کند که نشان می‌دهد آیا روش پیشنهادی قادر است عملکردی بهتر از یک مدل ساده و ابتدایی ارائه دهد یا خیر. با توجه به اینکه در زمینه مورد مطالعه این پایان‌نامه تاکنون پژوهش مستقیمی انجام نشده است، در تحقیقات پیشین روش پایه مشخصی معرفی نشده است. از این رو، لازم است با بهره‌گیری از تکنیک‌های آماری ساده، روش پایه‌ای تعریف شود تا نتایج مدل‌های پیشرفته‌تر قابل مقایسه باشند.



شکل ۱.۴: در این نمودار هر رنگ نماینده یک حوزه مهارتی است و محور عمودی میزان تخصص افراد بر اساس معیار score (میزان امتیازی که کاربران دیگر به پاسخ این کاربر در سایت stackoverflow داده اند) را نمایش می‌دهد. همچنین محور افقی سال‌های فعالیت این کاربر بین ۲۰۰۸ تا ۲۰۱۵ را نمایش می‌دهد.

برای تعریف روش پایه، رویکردهای متنوعی قابل تصور هستند؛ به عنوان مثال:

- در نظر گرفتن مقدار سال جدید دقیقاً برابر با مقدار سال قبل؛
- برآورد مقدار سال جدید بر اساس میانگین تمام سال‌های گذشته؛
- استفاده از میانگین وزن دار که در آن سال‌های اخیر وزن بیشتری نسبت به سال‌های قدیمی‌تر دارند؛
- به‌کارگیری روش‌های پیشرفته‌تر همچون مدل‌های سری زمانی آماری مانند ARIMA به‌عنوان روش پایه.

با وجود امکان استفاده از روش‌های پیچیده‌تر، در این پایان‌نامه به منظور سادگی و ایجاد معیاری شفاف برای مقایسه، روش پایه بر اساس **میانگین مقادیر سال‌های گذشته** انتخاب شده است. در این روش، مقدار پیش‌بینی‌شده برای سال جدید برابر با میانگین مقادیر سال‌های گذشته در نظر گرفته می‌شود. این رویکرد از یک سو پیاده‌سازی ساده‌ای دارد و از سوی دیگر معیاری منطقی و قابل اتکا برای ارزیابی عملکرد روش پیشنهادی ارائه می‌کند.

۲.۲.۴ توضیح و تعاریف

تعاریف متغیرها:

u شناسه کاربر (user)

s شاخص یا نماد یک حوزه مهارتی (skill)

t, y, y^* شاخص زمان یا سال؛ y^* سال پیش‌بینی شده (target). (year)

a یک عنصر فعالیت (مثلاً یک پاسخ یا پست) مربوط به کاربر در یک مهارت و سال.

$A_{u,s,t}$ مجموعه تمام عناصر a مربوط به کاربر u در مهارت s و سال t .

$\text{score}(a)$ مقدار امتیاز اختصاص یافته به عنصر a (مثلاً تعداد رأی‌های مثبت).

$x_{u,s,t}$ مقدار تجمعی خام امتیازها برای کاربر u ، مهارت s و سال t (مثلاً $\text{score}(a)$ $a \in A_{u,s,t}$).

$\tilde{x}_{u,s,t}$ مقدار تبدیل شده لگاریتمی $x_{u,s,t}$ (مثلاً $\tilde{x} = \log(1 + x)$).

$a_{u,s,y}$ نماد دیگری برای مقدار خام تجمعی کاربر-مهارت-سال (معادل $x_{u,s,t}$ در بخش‌های دیگر متن).

$T_{s,y}$ مجموع مقادیر یک مهارت s در سال y بر روی همه کاربران: $T_{s,y} = \sum_u a_{u,s,y}$

$U_{u,y}$ مجموع مقادیر همه مهارت‌ها برای کاربر u در سال y : $U_{u,y} = \sum_s a_{u,s,y}$

ε ثابت کوچک برای پایداری عددی و جلوگیری از تقسیم بر صفر (مثلاً 10^{-8}).

$n_{u,s,y}^{(6)}$ مقدار نرم‌شده طبق استراتژی ۶ (Skill-Year): $n_{u,s,y}^{(6)} = \frac{a_{u,s,y}}{T_{s,y} + \varepsilon}$ Normalization

$n_{u,s,y}^{(1)}$ مقدار نرم‌شده طبق استراتژی ۱ (User-Year): $n_{u,s,y}^{(1)} = \frac{a_{u,s,y}}{U_{u,y} + \varepsilon}$ Normalization

$\hat{n}_{u,y^*}^{(6)}, \hat{n}_{u,s,y^*}^{(6)}$ بردار / مؤلفه‌های پیش‌بینی شده در فضای نرم‌شده Strategy ۶.

$\hat{a}_{u,s,y^*}$ پیش‌بینی بازگردانده شده به مقیاس خام برای کاربر u ، مهارت s و سال y^* .

پیش‌بینی نرم‌شده نهایی در فضای Strategy ۱ برای ارزیابی. $\hat{n}_{u,s,y^*}^{(1)}, \hat{n}_{u,y^*}^{(1)}$

$n_{u,y^*}^{(1)}$ بردار پروفایل واقعی کاربر u در سال y^* پس از نرم‌سازی Strategy ۱.

$\|\cdot\|_2$ نرم اقلیدسی (Euclidean) (norm بردار: $\|\mathbf{v}\|_2 = \sqrt{\sum_i v_i^2}$).

$\cosine(\cdot, \cdot)$ کسینوس شباهت بین دو بردار؛ معیار ارزیابی برای تطابق توزیع مهارت‌ها.

۳.۴ ساخت مجموعه داده

همانطور که پیشتر گفته شد برای این پایان‌نامه از داده‌های خام وبسایت StackOverflow استفاده شده است. این داده‌ها شامل متن پرسش‌ها، متن پاسخ‌ها، امتیاز هر پرسش و پاسخ، تاریخ ثبت پرسش یا پاسخ، برچسب‌های مرتبط با هر پرسش (نمایانگر موضوع یا حوزه‌ی مطرح‌شده) و همچنین شناسه‌ی کاربری ایجادکننده‌ی پرسش یا پاسخ می‌باشد. با این حال، برای ساخت مجموعه‌داده‌ی مناسب به منظور حل مسئله‌ی پیش‌بینی تخصص کاربران، تنها به چهار ویژگی کلیدی نیاز است: شناسه‌ی کاربر، حوزه‌ی مهارتی، تاریخ فعالیت و امتیاز. تمام این اطلاعات (به جز حوزه‌های مهارتی) در مجموعه‌داده‌ی اولیه وجود داشت. برای استخراج حوزه‌های مهارتی از کاربران، مطابق با رویکرد ارائه‌شده در مقاله‌ی رستمی و همکاران، پرسش‌ها و پاسخ‌ها با استفاده از یک الگوریتم خوشه‌بندی گروه‌بندی شدند تا حوزه‌های مهارتی حاصل گردد [۱۹].


۱.۳.۴ خوشه‌بندی

برای انجام خوشه‌بندی، پرسش‌ها و پاسخ‌های مرتبط با زبان برنامه‌نویسی Java انتخاب شدند. دلیل این انتخاب، حجم بالاتر داده‌های مربوط به Java نسبت به سایر زبان‌ها و فناوری‌ها در StackOverflow بود. فرآیند خوشه‌بندی با استفاده از روش خوشه‌بندی تجمیعی^۱ انجام گرفت و در نتیجه برچسب‌های مشابه در یک خوشه قرارگرفتند. برچسب‌های مرتبط با هر حوزه‌ی مهارتی در شکل ۲.۴ ارائه شده‌اند. با توجه به اینکه الگوریتم‌های خوشه‌بندی نام‌های قابل درکی برای انسان تولید نمی‌کنند، در این پژوهش از مدل‌های زبانی^۲ بزرگ برای نام‌گذاری

^۱ Clustering Agglomerative

^۲ LLMs

۱.۴ نمایش داده شده‌اند.



۴.۴ پیش‌پردازش و مهندسی ویژگی

در حال حاضر داده‌های موجود شامل چهار ویژگی هستند: شناسه کاربر، تاریخ فعالیت، امتیاز کاربر و حوزه مهارتی. تاریخ فعالیت کاربر یک تاریخ دقیق شامل سال، ماه، روز و ساعت فعالیت است؛ در نتیجه یک کاربر ممکن است در یک سال بیش از یک داده داشته باشد. از آنجا که در مسئله مطرح شده قصد داریم مهارت کاربر

Name	SkillArea	Name	SkillArea	Name	SkillArea
		jpa	J	ExcelPOI	A
Graphics	T	struts	K	Log4J	B
audio	U	tomcat	L	SeriJSON	C
Cloud	V	WebSessions	N	XML-Java	D
Concurrency	W	Interop	O	RESTful	E
Security	X	Swing	P	SOAP-based	F
Networking	Y	OOP	Q	testing	G
jboss	Z	Search	R	spring	H
maven	AA	Text	S	hibernate	I

جدول ۱.۴: نام‌های تولید شده به وسیله مدل‌های زبانی بزرگ برای هر حوزه مهارتی خوشه‌بندی شده را نشان می‌دهد.

را به ازای هر سال فعالیت بررسی کرده و در نهایت مهارت‌های کاربر را در سال بعد پیش‌بینی کنیم، لازم است که تمام امتیازهای یک کاربر در یک حوزه مهارتی و در یک سال جمع شود.

برای جمع امتیاز کاربران، شش تابع وجود دارد که می‌تواند در جمع این ویژگی به ما کمک کند:

- **تابع تعداد:** این تابع تعداد سطرهای داده در یک سال فعالیت کاربر را محاسبه می‌کند.
- **تابع جمع:** این تابع امتیازهای کاربر را در یک سال و در یک حوزه مهارتی خاص جمع می‌کند.
- **تابع میانگین:** این تابع میانگین امتیاز کاربر را در یک سال و در یک حوزه مهارتی محاسبه می‌کند.
- **تابع میانه:** این تابع میانه امتیاز کاربر را در یک سال و در یک حوزه مهارتی محاسبه می‌کند.
- **تابع بیشینه:** این تابع بیشینه امتیاز کاربر را در یک سال و در یک حوزه مهارتی محاسبه می‌کند.
- **تابع کمینه:** این تابع کمینه امتیاز کاربر را در یک سال و در یک حوزه مهارتی محاسبه می‌کند.


در بررسی‌های انجام‌شده، دو تابع میانگین و جمع نتایج مناسب‌تری برای این مسئله نشان دادند و برای این پژوهش از تابع تجمیعی جمع استفاده شده است. دلیل این انتخاب این است که علاوه بر میزان امتیاز دریافتی هر کاربر در سال، تعداد دفعاتی که آن کاربر در هر حوزه مهارتی تعامل داشته است نیز دارای اهمیت است؛ و تابع تجمیعی جمع می‌تواند توازنی میان دفعات تعامل و مجموع امتیازهای کاربر برقرار کند، در حالی که تابع میانگین وزن دفعات تعامل را در نظر نمی‌گیرد.

$$x_{u,s,t} = \sum_{a \in A_{u,s,t}} \text{score}(a)$$

در نهایت مجموعه داده شامل: سال فعالیت، مجموعه امتیاز کاربر (تجمیع‌شده)، شناسه کاربر و حوزه مهارتی او است. همان‌طور که مشخص است، برای آموزش بیشتر مدل‌های مبتنی بر یادگیری ماشین نیاز به نرمال‌سازی داده‌های عددی است. داده عددی موجود در این مسئله، عدد تجمیع‌شده امتیاز کاربران است. برای نرمال‌سازی از تکنیک min-max استفاده شده است.

اما مسئله اصلی روش نرمال‌سازی است. برای ساخت پروفایل کاربر در این مسئله از روشی استفاده شده که مهارت‌های هر کاربر به صورت مجزا در تمام حوزه‌ها آن کاربر در یک سال نسبت به هم نرمال می‌شوند؛ در نتیجه با مشاهده پروفایل کاربر در هر سال می‌توان سهم هر حوزه مهارتی در نمایه کاربر در آن سال را به صورت یک عدد بین صفر و یک بررسی کرد. در شکل ۳.۴ خروجی این روش نرمال‌سازی برای یک کاربر نمونه قابل مشاهده است. بنابراین برای ساخت پروفایل کاربر، این روش نرمال‌سازی گزینه مناسبی به نظر می‌رسد.

با این حال، در تلاش‌های انجام‌شده برای آموزش مدل با استفاده از این روش نرمال‌سازی، یک مشکل بزرگ مشاهده شد: وجود مقادیر بیش از حد برابر با 0 یا 1 مطلق. این مشکل باعث بروز مسائل در فرآیند آموزش مدل از جمله عدم بهبود مدل در هر دوره و در نتیجه کاهش دقت مدل می‌شود. بنابراین نیاز دیده شد که روش‌های دیگر نرمال‌سازی نیز بررسی و آزمایش شوند.



شکل ۳.۴: در این شکل روند تغییرات مهارت‌های یک فرد نمونه بین سال‌های ۲۰۰۸ تا ۲۰۱۵ قابل مشاهده است.

۱.۴.۴ بررسی روش‌های نرمال‌سازی

در این پژوهش، روش‌های نرمال‌سازی داده‌ها به شش دسته تقسیم شدند که هر یک مزایا و محدودیت‌های خاص خود را دارند. فرض کنید $x_{u,s,t}$ مقدار خام حوزه مهارتی s برای کاربر u در سال t باشد. ما شش روش نرمال‌سازی را بررسی می‌کنیم:

استراتژی اول - نرمال‌سازی بر اساس سال فعالیت کاربر

در این روش، امتیازهای هر کاربر در یک سال نسبت به یکدیگر نرمال می‌شوند. مزیت اصلی این رویکرد کاهش اثرات تجمع داده‌ها و نوسانات امتیاز در طول یک سال است و تا حدی مشکل ایستایی در یادگیری را کاهش می‌دهد. با این حال، این روش به تنهایی قادر به حل کامل مشکل نیست و برخی داده‌ها همچنان در بازه‌های اکستريم (صفر یا یک مطلق) باقی می‌مانند.

$$\hat{x}_{u,s,t} = \frac{x_{u,s,t}}{\sum_{s' \in S} x_{u,s',t}}$$

استراتژی دوم - نرمال سازی بر اساس تمام مهارت های کاربر در تمام سال ها

در این رویکرد، امتیازهای یک کاربر در تمامی سال های فعالیت نسبت به یکدیگر مقیاس بندی می شوند. این روش باعث می شود تغییرات مهارتی کاربر در طول زمان قابل مقایسه تر شوند و مشکل ایستایی در یادگیری تا حدی کاهش یابد. با این حال، تأثیر تغییرات جمعیتی کاربران و رشد کلی پلتفرم بر امتیازات ثبت شده همچنان بر جا می ماند و نمی توان آن را به طور کامل خنثی کرد.

$$\hat{x}_{u,s,t} = \frac{x_{u,s,t}}{\sum_{s' \in S} \sum_{\tau \in T} x_{u,s',\tau}}$$

استراتژی سوم - نرمال سازی بر اساس تمامی سال ها، تمام کاربران به تفکیک مهارت

در این روش، هر حوزه مهارتی یک کمینه (عدد ۰) و یک بیشینه (عدد ۱) دریافت کرده و باقی سطرهای مرتبط با این مهارت عدد بین صفر و یک دریافت می کنند. در این روش بیشتر داده های تولید شده نزدیک به عدد صفر هستند.

$$\hat{x}_{u,s,t} = \frac{x_{u,s,t}}{\sum_{u' \in U} \sum_{s' \in S} \sum_{\tau \in T} x_{u',s',\tau}}$$

استراتژی چهارم - نرمال سازی بر اساس تمامی سال ها، تمامی کاربران و تمامی حوزه های مهارتی

در این روش، بیشترین امتیاز موجود در کل مجموعه داده به مقدار ۱ و کمترین امتیاز به مقدار صفر نگاشت می شوند و سایر مقادیر بین این دو مقدار قرار می گیرند. مزیت این رویکرد، مقیاس بندی یکپارچه تمام داده ها است. اما مشکل اصلی، توزیع نامناسب داده ها است؛ به گونه ای که اکثر داده ها در بازه ی ۰ تا ۲۵.۰ قرار می گیرند و تقریباً هیچ داده ای بین ۷۵.۰ تا ۱ مشاهده نمی شود. این نابرابری در توزیع باعث می شود مدل آموزش داده شده در بازه های بالاتر داده ها ضعیف عمل کند.

$$\hat{x}_{u,s,t} = \frac{x_{u,s,t}}{\sum_{u' \in U} \sum_{\tau \in T} x_{u',s,\tau}}$$

استراتژی پنجم - نرمال سازی بر اساس حوزه های مهارتی در هر سال، بدون تفکیک کاربر

در این رویکرد، داده ها برای هر حوزه ی مهارتی در هر سال مستقل نرمال می شوند، بدون آنکه هویت کاربران در نظر گرفته شود. این روش توزیع مناسب تری از داده ها ایجاد می کند و اثرات ناشی از تغییر تعداد کاربران در طول زمان را کاهش می دهد.

$$\hat{x}_{u,s,t} = \frac{x_{u,s,t}}{\sum_{u' \in U} \sum_{s' \in S} x_{u',s',t}}$$

استراتژی ششم - نرمال سازی بر اساس داده های تمام کاربران و تمام حوزه های مهارتی در هر سال

این روش مشابه روش چهارم است، با این تفاوت که تمام کاربران و حوزه های مهارتی در مقیاس بندی هر سال لحاظ می شوند. نتیجه این نرمال سازی، ایجاد توزیع نرمال تر و یکنواخت تر داده ها و کاهش اثرات انحراف ناشی از داده های بیش نمایش است.

$$\hat{x}_{u,s,t} = \frac{x_{u,s,t}}{\sum_{u' \in U} x_{u',s,t}}$$

نسبت یک ها به کل	نسبت صفرها به کل	روش نرمال سازی
0.155	0.6282	نرمال سازی بر اساس سال فعالیت کاربر
0.1367	0.5211	نرمال سازی بر اساس تمام مهارت های کاربر در تمام سال ها
0.0001	0.0001	نرمال سازی بر اساس تمامی سال ها، تمامی کاربران و به تفکیک حوزه های مهارتی
0	0	نرمال سازی بر اساس تمامی سال ها، تمامی کاربران و تمام حوزه های مهارتی
0	0	نرمال سازی بر اساس تمام حوزه های مهارتی در هر سال
0.0007	0.0019	نرمال سازی بر اساس حوزه های مهارتی در هر سال، بدون تفکیک کاربر
0.0007	0.0019	نرمال سازی بر اساس حوزه های مهارتی در هر سال، بدون تفکیک کاربر با مقیاس لگاریتم

جدول ۲.۴: مقایسه روش های مختلف نرمال سازی و نسبت مقادیر صفر و یک در داده ها

۲.۴.۴ تحلیل و دلیل انتخاب روش نهایی

همان طور که در شکل ۵.۴ مشخص است، روش های پنجم و ششم از نظر توزیع نرمال داده ها عملکرد بهتری نسبت به چهار روش دیگر نشان دادند. علاوه بر این، دلایل منطقی نیز وجود دارد که این دو روش مناسب تر به نظر می رسند. وبسایت StackOverflow در طول زمان شاهد رشد قابل توجهی در تعداد کاربران بوده است [۴۲، ۴۳]؛ این رشد بر تعاملات کاربران تأثیر می گذارد و باعث افزایش امتیازات ثبت شده برای پرسش ها و پاسخ های مشابه می شود. به عبارت دیگر، با افزایش کاربران، ثبت امتیازها برای مهارت های مشابه در سال های بعدی به طور طبیعی افزایش می یابد.

با نرمال سازی بر اساس سال، اثر رشد کاربران در طول زمان تا حد زیادی تعدیل می شود و مدل آموزش داده شده قادر خواهد بود مهارت واقعی کاربران را در هر سال بهتر بازنمایی کند، بدون آنکه تحت تأثیر تغییرات جمعیتی و افزایش تعاملات کلی قرار گیرد. به این ترتیب، سهم هر حوزه ی مهارتی در پروفایل سالانه ی کاربر با دقت بیشتری آشکار می شود و مشکل مقادیر صفر یا یک مطلق که در روش های اولیه مشاهده شده بود، به طور قابل توجهی کاهش می یابد.

از میان دو روش نهایی، روشی که نرمال سازی را به صورت سالانه و به تفکیک هر حوزه مهارتی انجام می دهد، انتخاب بهتری است. زیرا در وبسایت StackOverflow مهارت های پرتعداد معمولاً امتیازهای بیشتری در پرسش ها و پاسخ ها دریافت می کنند؛ اما محبوب تر بودن یک مهارت الزماً نشان دهنده مهارت بالاتر افراد فعال در آن حوزه نیست. در صورت ادغام تمامی حوزه ها در یک نرمال سازی کلی، مدل ممکن است افرادی را که در مهارت های پرتعداد فعال بوده اند، به اشتباه خبره تر تشخیص دهد. نرمال سازی به تفکیک حوزه های مهارتی این سوگیری را تعدیل می کند و به مدل در پیش بینی بهتر توانایی های واقعی افراد کمک می کند.

در نتیجه، ما برای آموزش و پیش بینی مدل از «استراتژی ۶» استفاده می کنیم؛ ولی برای ارزیابی مدل و همچنین ساخت نمایه کاربران، «روش یک» مناسب تر است، زیرا سهم هر مهارت را به تفکیک در هر سال فعالیت کاربر مشخص می کند. بر این اساس، چارچوب آداپتری پیشنهاد می شود که به صورت زنجیروار عمل می کند: ابتدا داده جدید با استراتژی ۶ نرمال سازی می شود و پیش بینی توسط مدل انجام می گیرد؛ سپس خروجی پیش بینی به مقیاس اصلی بازگردانده (غیرنرمال سازی) می شود و در نهایت با استفاده از روش یک، نرمال سازی مجدد انجام

می‌گیرد تا نمایه کاربر برای سال جدید استخراج شود. این رویکرد تضمین می‌کند که مدل هنگام پیش‌بینی از مزایای تعدیل اثر رشد کلی کاربران بهره‌مند شود و در عین حال نمایه نهایی تولیدشده برای اهداف ارزیابی و تحلیل، بازتاب‌دهنده سهم نسبی هر مهارت در سال مورد نظر باشد.

۵.۴ جدا سازی داده‌های آزمون از داده‌های آموزش مدل

روش معمول برای جداسازی داده‌های آموزش و آزمون در مسائل یادگیری ماشین تقسیم مجموعه داده به دو بخش معمولاً نامساوی، آموزش مدل و سپس ارزیابی مدل با داده‌های آزمون است. این تقسیم معمولاً بر اساس سطرهای داده انجام می‌شود. ولی در مجموعه داده موجود از آنجایی که اطلاعات هر کاربر در چندین سطر وجود دارد تقسیم داده‌های تستی بر اساس سطر داده باعث می‌شود که برخی کاربران هم در داده آزمون و هم در داده آموزش حضور داشته باشند. این موضوع باعث می‌شود که نتوان پیش‌بینی دقیق از آن کاربر داشت و مدل نیز اطلاعات ناقصی از کاربرانی که آموزش با آن‌ها انجام می‌شود خواهد داشت. در نتیجه روش بهتر تقسیم بندی کاربران به دو گروه ۲۰٪ و ۸۰٪ است. به طوری که کاربران گروه ۸۰٪ برای آموزش مدل استفاده شده و باقی برای ارزیابی و بررسی میزان دقت پیش‌بینی استفاده می‌شوند.

۶.۴ انتخاب مدل

در این پژوهش برای حل مسئله مورد نظر از یک شبکه‌ی عصبی پیشخور با چند لایه‌ی تمام‌متصل استفاده شد. دلیل انتخاب این ساختار، سادگی، انعطاف‌پذیری و توانایی آن در تقریب توابع غیرخطی پیچیده است. به‌منظور بهبود همگرایی و جلوگیری از بروز مشکلاتی نظیر تغییر توزیع داده‌ها در طول آموزش، از لایه‌های Batch Normalization استفاده شد. همچنین برای کاهش بیش‌برازش در فرآیند آموزش، لایه‌های Dropout به مدل اضافه شدند. این ترکیب به‌عنوان یکی از معماری‌های متداول و کارآمد در مسائل مشابه گزارش شده است و با توجه به محدودیت‌های محاسباتی و داده‌های موجود، انتخاب مناسبی برای این پژوهش محسوب می‌شود. همچنین لازم به ذکر است برای آموزش مدل از کتابخانه tensorflow و زبان برنامه نویسی پایتون استفاده شده است.

۷.۴ آموزش مدل

برای آموزش مدل از روش‌های اعتبارسنجی متقاطع^۱ استفاده شد تا ارزیابی قابل اعتماد و انتخاب مناسب ابرپارامترها ممکن شود؛ تقسیم‌بندی داده‌ها به گونه‌ای انجام شد که نمونه‌های مربوط به یک کاربر یا بازه زمانی مشخص در یک بخش قرار گیرند تا از نشت اطلاعات جلوگیری شود. در فرآیند آموزش، معیارهای عددی و برداری مرتبط با هدف نهایی (از جمله معیارهای مربوط به شباهت پروفایل‌ها) پایش شده و تنظیمات مدل بر اساس عملکرد میانگین در تاخورها انتخاب شد.

برای جلوگیری از بیش‌برازش از مکانیزم Stopping Early بهره برده شد؛ مدل در هر تکرار روی مجموعه اعتبارسنجی پایش شده و در صورت عدم بهبود، آموزش متوقف و وزن‌های دوره بهترین عملکرد بازیابی می‌شوند. این ترکیب اعتبارسنجی متقاطع و توقف زودهنگام تضمین می‌کند که مدل هم از نظر تعمیم‌پذیری محک زده شود و هم از رشد بیش از حد پیچیدگی در فرآیند یادگیری جلوگیری گردد.

۸.۴ چارچوب آداپتور برای پیش‌بینی بین‌مقیاسی

برای همسوسازی روش‌های مختلف نرمال‌سازی که در طی آموزش و ارزیابی به کار می‌روند و از آن جایی که ما از دو روش متفاوت نرمال‌سازی برای آموزش مدل و ارزیابی استفاده می‌کنیم، ما یک چارچوب آداپتور توسعه می‌دهیم که به ترتیب (۱) مقادیر خام تجمیع‌شده مهارت را به فضای ورودی مدل می‌برد (استراتژی ۶)، (۲) پیش‌بینی‌کننده آموزش‌دیده را در آن فضا اجرا می‌کند تا پیش‌بینی حاصل شود، و (۳) پیش‌بینی را مجدداً به فضای ارزیابی بازمی‌گرداند (استراتژی ۱). این آداپتور تضمین می‌کند که مدل روی نرمال‌سازی‌ای آموزش ببیند که سوگیری ناشی از رشد جمعیت را کاهش می‌دهد (استراتژی ۶)، در حالی که ارزیابی و استفاده‌های بعدی (رتبه‌بندی، شباهت کسینوسی) بر اساس مقیاس نسبی «هر کاربر در هر سال» (استراتژی ۱) انجام می‌شود.

^۱ cross-validation

نمادها. فرض کنید $a_{u,s,y}$ مقدار خام تجميع شده مهارت برای کاربر u ، حوزه مهارتی s و سال y باشد (مجموع امتیازهای فعالیت برای آن مثلث کاربر-حوزه-سال). مجموع سالانه بر حسب هر حوزه را تعریف می کنیم:

$$T_{s,y} = \sum_u a_{u,s,y}, \quad (۱.۴)$$

و مجموع سالانه هر کاربر را به صورت

$$U_{u,y} = \sum_s a_{u,s,y}. \quad (۲.۴)$$

برای پایداری عددی از ε (ثابت مثبت کوچک، مثلاً 10^{-8}) استفاده می کنیم.

نرمال سازی استراتژی ۶ (ورودی مدل) به صورت نسبت عنصر به عنصر تعریف می شود:

$$n_{u,s,y}^{(6)} = \frac{a_{u,s,y}}{T_{s,y} + \varepsilon}, \quad (۳.۴)$$

و نرمال سازی استراتژی ۱ (پرو فایل هر کاربر برای ارزیابی) به صورت

$$n_{u,s,y}^{(1)} = \frac{a_{u,s,y}}{U_{u,y} + \varepsilon}. \quad (۴.۴)$$

۱.۸.۴ خط لوله آدپتور

برای هر کاربر آزمایشی u و سال پیش بینی y^* (مثلاً ۲۰۱۵)، آدپتور مراحل زیر را اجرا می کند:

۱. محاسبه ثابت های مقیاس دهی. مقادیر $T_{s,y}$ مربوط به سال های مرتبط (به ویژه T_{s,y^*}) را بازیابی کنید و

بردارهای خام تاریخی کاربر $a_{u,\cdot,y}$ را در اختیار داشته باشید.

۲. نرمال سازی ورودی ها (استراتژی ۶). برای هر سال تاریخی $y < y^*$ که به عنوان ورودی قرار می گیرد،

بردار $\mathbf{n}_{u,y}^{(6)} = (n_{u,s,y}^{(6)})_s$ از معادله (۳.۴) را تشکیل دهید. بردارهای تاریخی را مطابق قالب ورودی مدل،

پشته کنید.

۳. پیش بینی در فضای استراتژی ۶. ورودی پشته شده را به مدل آموزش دیده بدهید و خروجی $\hat{\mathbf{n}}_{u,y^*}^{(6)}$

را دریافت کنید.

۴. واگرد به مقیاس خام. پیش‌بینی‌ها را برای سال y^* به مقیاس تجمیع‌شده خام تبدیل کنید:

$$\hat{a}_{u,s,y^*} = \hat{n}_{u,s,y^*}^{(6)} \cdot (T_{s,y^*} + \varepsilon).$$

۵. نرمال‌سازی مجدد با استراتژی ۱. پروفایل پیش‌بینی‌شده هر کاربر را برای ارزیابی تهیه کنید:


$$\hat{n}_{u,s,y^*}^{(1)} = \frac{\hat{a}_{u,s,y^*}}{\sum_s \hat{a}_{u,s,y^*} + \varepsilon}.$$

۶. ارزیابی / پروفایل نهایی. از $\hat{n}_{u,y^*}^{(1)}$ برای محاسبه شباهت کسینوسی نسبت به پروفایل واقعی کاربر $\mathbf{n}_{u,y^*}^{(1)}$ استفاده کنید.


۲.۸.۴ جمع‌بندی

در این فصل روند کلی آماده‌سازی و پردازش داده‌ها برای مسئله پیش‌بینی بیان شد؛ به‌ویژه روش‌های نرمال‌سازی مورد استفاده برای تبدیل مقادیر خام به فضای ورودی مدل توضیح داده شد. همچنین نوع مدل مورد استفاده و رویکرد آموزشی (شامل تقسیم‌بندی داده‌ها برای اعتبارسنجی و مکانیسم جلوگیری از بیش‌برازش) تشریح شد تا خواننده تصویری جامع از فرایند یادگیری به‌دست آورد. در کنار این‌ها، روش‌های ارزیابی که برای سنجش کیفیت پیش‌بینی‌ها به‌کار رفته‌اند معرفی گردید تا پیوند میان اهداف کاربردی و معیارهای کمی روشن شود.

در بخش آینده نتایج ارزیابی معرفی شده و این نتایج با روش پایه مقایسه می‌شوند.



شکل ۴.۴: نشان دهنده نمودارهای histogram و plot qq برای حالت های مختلف نرمال سازی است. نمودار اول از بالا روش نرمال سازی بر اساس سال فعالیت کاربر را نشان می دهد. همانطور که مشاهده می کنید بیشتر داده ها اعداد یک و صفر هستند. نمودار دوم نرمال سازی بر اساس تمام مهارت های کاربر در تمام سال ها است. همانطور که مشخص است تعداد اعداد غیر از صفر و یک کمی بیشتر شده ولی بازهم درصد بزرگی از داده ها را این اعداد تشکیل می دهند. نمودار سوم نرمال سازی بر اساس تمام کاربران در تمام سال ها را نشان می دهند که بیشتر اعداد در این روش نزدیک به صفر هستند و توزیع مناسبی ندارند. نمودار پنجم و ششم نرمال سازی بر اساس سال برای تمام کاربران را نشان می دهد. همانطور که مشخص است کمی تعداد اعداد نزدیک به صفر کمتر شده و نمودار اعداد دیگری را نیز نمایش می دهد. شکل آخر اعمال مقیاس لگاریتمی روی داده ها را نمایش می دهد که باعث ایجاد توزیع نرمال در داده ها شده و نمودار plot qq بیشتر داده ها را روی محور اصلی نمایش می دهد. همچنین نمودار histogram به نیز بیانگر این توزیع مناسب است.



شکل ۵.۴: رشد کاربران Overflow Stack در گذر زمان بر اساس داده‌های موجود بین سال‌های ۲۰۰۸ تا ۲۰۱۵ میلادی. نکته قابل توجه این است که کاهش رشد در سال ۲۰۱۵ به دلیل جمع‌آوری داده در اواسط سال ۲۰۱۵ است؛ بنابراین مجموعه داده شامل تمام داده‌های سال ۲۰۱۵ نیست.

فصل ۵

ارزیابی روش پیشنهادی

۱.۵ مقدمه

هدف این فصل ارائه نتایج ارزیابی روش پیشنهادی و اندازه‌گیری دقت مدل ارائه شده در فصل قبل است، که پاسخ‌های تحلیلی به سؤالات پژوهشی مطرح‌شده در فصل اول را فراهم می‌آورد. با توجه به اینکه مراحل ساخت مجموعه داده، روش‌های پیش‌پردازش، استراتژی‌های نرمال‌سازی، چارچوب آداپتور و جزئیات معماری مدل در فصل پیشین (فصل ۴) به تفصیل تشریح شده‌اند، در این فصل از تکرار کامل آن مطالب پرهیز شده و تمرکز بر روی اندازه‌گیری نتیجه با استفاده از داده‌های موجود از فعالیت کاربران در وبسایت StackOverflow است. در این فصل به‌طور خاص موارد زیر گزارش می‌شوند:

- خلاصه‌ای از مجموعه داده‌ها و گروه‌های آزمون مورد استفاده (ارجاع به فصل ۴ برای جزئیات کامل).
- پروتکل ارزیابی و روش محاسبه دقت پیش‌بینی
- روش‌های مرجع (baseline) که برای مقایسه انتخاب شده‌اند و دلایل انتخاب هر یک (از جمله روش میانگین مقادیر گذشته که در فصل ۴ معرفی شد).
- گزارش عددی نتایج و مقایسه روش ارائه شده با روش مرجع

برای سنجش تطابق بین نمایه پیش‌بینی شده و نمایه واقعی کاربران در سال هدف، معیار اصلی ارزیابی $C_{\text{similarity sine}}$ در نظر گرفته شده است. توضیحات دقیق‌تر و فرمول رسمی این معیار در بخش مربوطه ارائه خواهد شد.

در پایان فصل، نتایج به‌صورت تحلیلی عرضه می‌شوند تا پاسخ روشی به سؤالات پژوهشی ارائه گردد و سهم پژوهش در توسعه کاربردی پیش‌بینی تخصص کاربران با استناد به شواهد تجربی بیان شود.

۲.۵ مجموعه داده

همان‌طور که در فصل چهارم توضیح داده شد، داده‌های مورد استفاده در این پژوهش از پرسش‌ها و پاسخ‌های وبسایت StackOverflow استخراج گردیدند. پس از فرآیندهای استخراج، تطبیق برچسب و پالایش اولیه،

مجموعه نهایی شامل 111,367 نمونه کاربران است. هر نمونه نماینده یک کاربر بوده و شامل مجموعه‌ای از حوزه‌های مهارتی و مقادیر تجمیع شده امتیاز در بازه زمانی ۲۰۰۸ تا ۲۰۱۵ می‌باشد. تمامی مراحل پیش‌پردازش و مهندسی ویژگی (از جمله تجمیع امتیازات در سطح سالانه، تبدیل‌های لازم و نرمال‌سازی طبق استراتژی‌های معرفی شده در فصل چهارم) بر روی این داده‌ها اعمال شده است.

۳.۵ معیار ارزیابی

در این پژوهش، بردار نمایه واقعی هر کاربر در سال هدف (۲۰۱۵) و بردار پیش‌بینی شده توسط مدل با یکدیگر مقایسه می‌شوند و برای سنجش تطابق الگوهای مهارتی از **شباهت کسینوسی** استفاده شده است. شباهت کسینوسی دو بردار u و v را به صورت زیر تعریف می‌کنیم:

$$\text{sim}_{\cos}(u, v) = \frac{u \cdot v}{\|u\|_2 \|v\|_2}.$$

چون در این مسئله بردارها نمایانگر سهم نسبی مهارت‌ها (یا پروفایل نرمال شده مهارتی) هستند، مقدار شباهت کسینوسی در بازه $[0, 1]$ قرار می‌گیرد و مقادیر نزدیک به یک نشان‌دهنده تطابق قوی الگوی نسبی مهارتی بین پیش‌بینی و واقعیت است. برای گزارش عملکرد، توزیع مقادیر شباهت کسینوسی بر روی مجموعه آزمون (میانگین، میانه، انحراف معیار و نمودارهای توزیع) ارائه می‌گردد.

انتخاب شباهت کسینوسی مبتنی بر این نکته است که هدف اصلی مسئله، تطبیق الگوی نسبی مهارت‌ها (نسبت هر مهارت در پروفایل کاربر) است نه برابری مقادیر مطلق فعالیت. شباهت کسینوسی جهت بردارها را می‌سنجد و نسبت به اختلاف مقیاس (حجم کل تعاملات کاربر) مقاوم است؛ بنابراین اگر یک کاربر در دو بردار مقایسه شده حجم کلی فعالیت متفاوتی داشته باشد اما توزیع نسبی مهارت‌هایش یکسان باشد، شباهت کسینوسی مقدار بالایی خواهد داد در حالی که معیارهایی مانند MAE به دلیل اندازه‌گیری اختلاف مطلق بین مؤلفه‌ها مقدار خطای بزرگی گزارش می‌کنند. به عبارت دیگر، MAE تفاوت مقدار در هر مؤلفه را اندازه‌گیری می‌کند و تصویر کلی الگورا منعکس نمی‌سازد، در حالی که شباهت کسینوسی مستقیماً نشان‌دهنده تشابه الگوی مهارتی است. علاوه بر این، شباهت کسینوسی محاسباتی سبک و تفسیرپذیر دارد و برای تحلیل‌های کیفی (مثلاً انتخاب نمونه‌های «موفق» و «ناموفق» جهت بررسی علت خطا) مناسب‌تر است. از این رو در این پایان‌نامه تنها از

شباهت کسینوسی برای ارزیابی کیفیت پیش‌بینی نمایه‌ها استفاده شده است.

۴.۵ فرآیند ارزیابی

ارزیابی عملکرد مدل به صورت زیر اجرا می‌شود. هدف نهایی محاسبه میانگین شباهت کسینوسی بین نمایه پیش‌بینی شده و نمایه واقعی کاربران در سال هدف (۲۰۱۵) است.

۱. **پیش‌بینی مهارت‌ها.** برای هر کاربر آزمایشی u و برای هر حوزه مهارتی s ، مدل مقدار پیش‌بینی شده را در فضای ورودی مدل تولید می‌کند؛ نتیجه این مرحله بردار پیش‌بینی شده نرم شده در قالب استراتژی 6 است، یعنی $\hat{\mathbf{n}}_{u,y}^{(6)}$.

۲. **واگرد آدپتور به مقیاس ارزیابی.** مطابق چارچوب آدپتور (بخش ۸.۴)، پیش‌بینی‌های $\hat{\mathbf{n}}_{u,y}^{(6)}$ ابتدا به مقیاس خام $\hat{a}_{u,s,y}$ بازگردانده می‌شوند و سپس با استفاده از استراتژی 1 نرمال سازی شده تا بردار پروفایل پیش‌بینی شده نهایی $\hat{\mathbf{n}}_{u,y}^{(1)}$ حاصل گردد.

۳. **محاسبه شباهت کسینوسی هر کاربر.** برای هر کاربر u مقدار شباهت کسینوسی بین پروفایل پیش‌بینی شده و پروفایل واقعی سال هدف محاسبه می‌شود:

$$\text{sim}(u) = \text{sim}(\hat{\mathbf{n}}_{u,y}^{(1)}, \mathbf{n}_{u,y}^{(1)}) = \frac{\hat{\mathbf{n}}_{u,y}^{(1)} \cdot \mathbf{n}_{u,y}^{(1)}}{\|\hat{\mathbf{n}}_{u,y}^{(1)}\|_2 \|\mathbf{n}_{u,y}^{(1)}\|_2}.$$

۴. **ادغام نتایج به عنوان معیار نهایی.** دقت کلی مدل بر حسب میانگین مقادیر شباهت کسینوسی بر روی مجموعه کاربران آزمون U_{test} گزارش می‌شود:

$$\overline{\text{sim}} = \frac{1}{|U_{\text{test}}|} \sum_{u \in U_{\text{test}}} \text{sim}(u).$$

۵.۵ مقایسه دقت

پس از محاسبه دقت مدل پیشنهادی (معرفی شده در فصل قبل)، دقت روش پایه نیز محاسبه شد. در روش پایه، مقدار هر مهارت کاربر در سال ۲۰۱۵ به صورت میانگین مقادیر همان مهارت در سال‌های پیشین کاربر در

نظر گرفته شد. به منظور تضمین شرایط عادلانه، این محاسبات صرفاً بر روی داده‌های مجموعه‌آزمون انجام گرفت تا هر دو روش، ورودی‌های یکسانی داشته باشند.

جدول ۱.۵ مقادیر میانگین شباهت کسینوسی به دست آمده از مدل پیشنهادی و روش پایه را نشان می‌دهد. همان‌طور که مشاهده می‌شود، مدل پیشنهادی توانسته است دقت بالاتری نسبت به روش پایه کسب کند و نتایج آن به نمایه واقعی کاربران نزدیک‌تر است.

جدول ۱.۵: مقایسه میانگین شباهت کسینوسی بین مدل پیشنهادی و روش پایه

روش	میانگین شباهت کسینوسی
روش پایه (میانگین سال‌های گذشته)	0.6485
مدل پیشنهادی	0.8825

۶.۵ جمع‌بندی

در این بخش، دقت مدل یادگیری ماشینی معرفی شده در فصل گذشته با دقت روش پایه مقایسه گردید تا کارآمدی رویکرد پیشنهادی در پیش‌بینی مهارت‌های آینده افراد مورد ارزیابی قرار گیرد. نتایج تجربی نشان می‌دهد که مدل پیشنهادی توانایی قابل توجهی در ارتقای دقت پیش‌بینی نسبت به روش مرجع دارد؛ این به معنای آن است که می‌توان با استفاده از ویژگی‌ها و ساختار پیشنهادی، الگوهای مرتبط با تحول مهارتی کاربران را به صورت مؤثرتری شناسایی کرد. با وجود این، محدودیت‌هایی از قبیل حساسیت مدل به پارامترهای یادگیری، حجم و پراکندگی داده‌های آموزش و نیاز به بررسی‌های گسترده‌تر برای ارزیابی قابلیت تعمیم‌پذیری در مجموعه داده‌های متفاوت وجود دارد. در فصل بعد، نتایج کلی پژوهش جمع‌بندی شده و براساس یافته‌ها، پیشنهاداتی برای کارهای پژوهشی آتی و توسعه کاربردی مدل ارائه خواهد شد.

فصل ۶

نتیجه‌گیری و کارهای آینده

۱.۶ مقدمه

این فصل به جمع بندی نهایی و ترسیم چشم انداز آینده پژوهش اختصاص دارد. در این بخش، ضمن مرور دستاوردهای اصلی، نتایج کلیدی تحقیق تفسیر می شوند و محدودیت های کار به همراه پیامدهای علمی و عملی آن مورد بحث قرار می گیرند. هدف نهایی، ارائه یک نقشه راه شفاف برای توسعه این حوزه و پژوهش های آتی است. در این پژوهش، یک مدل یادگیری ماشین برای پیش بینی مسیر تکامل مهارت های کاربران توسعه یافت. برای این منظور، با بهره گیری از تاریخچه فعالیت و ویژگی های رفتاری کاربران، مدلی طراحی، پیاده سازی و ارزیابی شد. نتایج نشان داد که رویکرد پیشنهادی با عملکردی برتر نسبت به روش پایه، توانایی قابل توجهی در مدل سازی و پیش بینی مهارت های آتی افراد دارد و می تواند به عنوان یک ابزار کارآمد در سیستم های تخصصی به کار گرفته شود.

۲.۶ نتایج کلیدی و تفسیر

ارزیابی کمی مدل، برتری چشمگیر رویکرد پیشنهادی را در مقایسه با روش پایه به اثبات رساند. مدل توسعه یافته به میانگین شباهت کسینوسی 0.8825 دست یافت که نشان دهنده بهبود نسبی 36 درصدی نسبت به امتیاز 0.6485 در روش پایه (میانگین سابقه) است.

این اختلاف قابل توجه، صرفاً یک بهبود عددی نیست؛ بلکه نشان می دهد که مدل یادگیری ماشین توانسته است الگوهای پیچیده و غیرخطی حاکم بر تکامل مهارت ها را بیاموزد. برخلاف روش پایه که نگاهی ایستا به گذشته دارد، مدل پیشنهادی قادر به درک پویایی تغییرات در پروفایل کاربران و پیش بینی مسیر آتی آن ها با دقت بسیار بالاتری است. این دستاورد، گامی مهم در جهت تحقق اهداف پژوهش، یعنی ساخت سیستم های هوشمندتر برای ارزیابی و پیش بینی تخصص، محسوب می شود و کارایی این رویکرد را برای کاربردهای عملی تأیید می کند.

۳.۶ کارهای آینده

اگرچه چارچوب پیشنهادی در این پژوهش توانسته است نتایج امیدبخشی در زمینه پیش بینی مهارت های آینده کاربران ارائه کند، اما همچنان زمینه های گوناگونی برای توسعه و بهبود وجود دارد. محدودیت های ذاتی داده ها، انتخاب بازه زمانی ثابت و نیز عدم بهره گیری از تحلیل محتوای متنی از جمله مواردی هستند که می توانند در مطالعات بعدی مورد توجه قرار گیرند. در ادامه، مسیرهای پیشنهادی برای پژوهش های آتی به تفصیل ارائه شده است.

۱.۳.۶ انعطاف پذیری در مقیاس زمانی

یکی از محدودیت های اساسی در معماری فعلی، نیاز به ورودی با اندازه و طول ثابت (داده های ۷ سال) است. این ساختار، مدل را به دو شکل محدود می کند:

۱. وابستگی به تاریخ: همانطور که اشاره شد، مدل فقط برای بازه ی زمانی ۲۰۰۸-۲۰۱۴ آموزش دیده است.

۲. وابستگی به طول تاریخچه: مدل نمی تواند کاربرانی را که سابقه ی فعالیت کمتر یا بیشتر از ۷ سال دارند، به درستی پردازش کند. این یک نقص بزرگ در کاربردهای واقعی است، زیرا تاریخچه ی کاربران بسیار متنوع است.

گام بلندپروازانه و بسیار ارزشمند برای کارهای آینده، طراحی یک مدل کاملاً پویا است که بتواند توالی هایی با هر طول دلخواه^۱ را به عنوان ورودی بپذیرد.

در این رویکرد، مدل قادر خواهد بود نمایه ی آتی یک کاربر را چه بر اساس ۲ سال سابقه ی فعالیت و چه بر اساس ۱۰ سال سابقه، پیش بینی کند. این انعطاف پذیری، کاربرد مدل را در دنیای واقعی به شدت افزایش می دهد و اجازه می دهد تا:

- متخصصان نوظهور با سابقه ی کم، به سرعت شناسایی و مسیر رشدشان پیش بینی شود.

^۱ Sequences Variable-Length

- متخصصان باتجربه با سابقه‌ی طولانی، با دقت بیشتری تحلیل شوند.

برای پیاده‌سازی چنین مدلی، باید از معماری‌های شبکه‌های عصبی^۱ که ذاتاً برای پردازش داده‌های ترتیبی طراحی شده‌اند، استفاده کرد. معماری‌هایی مانند شبکه‌های عصبی بازگشتی^۲ و به طور خاص مدل‌های LSTM^۳ یا GRU^۴، و همچنین معماری‌های مدرن‌تر مبتنی بر ترنسفورمر^۵، بهترین گزینه‌ها برای این هدف هستند. مهم‌ترین مزیت عملی این رویکرد آن است که سیستم پیش‌بینی می‌تواند به صورت مستمر و پویا فعال باشد. یعنی به محض اینکه داده‌های فعالیت کاربران در یک سال جدید (مثلاً سال ۲۰۲۵) در دسترس قرار گرفت، می‌توان بلافاصله تاریخچه‌ی به‌روز شده‌ی کاربران را به مدل داد و نمایه‌ی مهارتی آن‌ها برای سال آینده (۲۰۲۶) را پیش‌بینی کرد. این ویژگی، مدل را به یک ابزار همیشه فعال و آینده‌نگر تبدیل می‌کند.

۲.۳.۶ یادگیری تقویتی برای افزایش دقت مدل

برای اینکه مدل بتواند به صورت پویا با تغییرات محیط سازگار شود و دقت خود را در طول زمان بهینه کند، می‌توان مسئله‌ی پیش‌بینی را در چارچوب **یادگیری تقویتی**^۶ بازتعریف کرد. در این رویکرد، مدل نقش یک **عامل هوشمند**^۷ را ایفا می‌کند که با **محیط**^۸ در تعامل است و از بازخوردهای دریافتی به صورت مستمر می‌آموزد. محیط در اینجا همان بستر پویای مهارت‌ها و فعالیت کاربران در سامانه است. آنچه به عنوان **حالت**^۹ شناخته می‌شود، تاریخچه‌ی نمایه‌های مهارتی یک کاربر تا سال جاری است. **اقدام**^{۱۰} مدل، پیش‌بینی نمایه‌ی مهارتی کاربر برای سال آینده خواهد بود. پس از گذشت یک سال و مشخص شدن نمایه‌ی واقعی، به مدل یک **پاداش**^{۱۱} تعلق می‌گیرد که بر اساس میزان دقت پیش‌بینی (برای مثال با معیار شباهت کسینوسی) محاسبه می‌شود؛ اگر پیش‌بینی به

^۱ Networks Neural

^۲ (RNNs) Networks Neural Recurrent

^۳ (LSTM) Memory Short-Term Long

^۴ (GRU) Unit Recurrent Gated

^۵ Transformer

^۶ Learning Reinforcement

^۷ Agent

^۸ Environment

^۹ State

^{۱۰} Action

^{۱۱} Reward

واقعیت نزدیک باشد پاداش مثبت و در غیر این صورت پاداش منفی یا صفر خواهد بود.

با چنین ساختاری، مدل وارد چرخه‌ای از یادگیری مستمر می‌شود. در هر گام زمانی، یک پیش‌بینی انجام می‌دهد، بازخورد دریافت می‌کند و سپس سیاست درونی خود^۱ را به‌روزرسانی می‌کند تا در آینده پاداش بیشتری کسب کند. به این ترتیب، مدل به مرور استراتژی بهینه‌ای برای پیش‌بینی توسعه می‌دهد و می‌تواند خود را با روندهای جدید تطبیق دهد. مزیت اصلی این رویکرد آن است که مدل صرفاً به اصلاح خطاهای گذشته بسنده نمی‌کند، بلکه به‌صورت فعالانه به دنبال اتخاذ یک راهبرد بلندمدت است. این ویژگی، سیستم را به یک بستر هوشمند و خودبهبود^۲ تبدیل می‌کند که همواره با تغییرات محیط هماهنگ باقی می‌ماند.

۳.۳.۶ سنجش عمق واقعی دانش با تحلیل محتوای متنی

در پژوهش حاضر، معیار اصلی برای سنجش مهارت کاربر، امتیاز است که از رأی سایر کاربران به دست می‌آید. اگرچه این معیار تا حدی مفید است، اما لزوماً نمایانگر عمق واقعی دانش یک فرد نیست. امتیاز ممکن است تحت تأثیر عواملی مانند محبوبیت موضوع، زمان پاسخ‌دهی یا سادگی سؤال قرار گیرد و بنابراین قادر نباشد میان یک پاسخ سطحی به یک پرسش رایج و یک راه‌حل عمیق برای مسئله‌ای پیچیده تمایز قائل شود.

یک مسیر پژوهشی بسیار مهم در آینده، به‌کارگیری پردازش زبان طبیعی^۳ برای تحلیل مستقیم محتوای متنی پرسش‌ها و پاسخ‌هاست. از طریق این رویکرد می‌توان شاخص‌های غنی‌تری از تخصص را استخراج کرد. برای نمونه، پیچیدگی مفاهیم و کد را می‌توان با تحلیل واژگان فنی، ساختار کد و الگوریتم‌های ارائه‌شده در پاسخ‌ها سنجید. همچنین کیفیت توضیح را می‌توان با ارزیابی وضوح، جامعیت و توانایی کاربر در انتقال مفاهیم دشوار به دیگران اندازه‌گیری کرد. علاوه بر این، سطح دشواری مسائل نیز قابل تشخیص است، به‌گونه‌ای که می‌توان دریافت آیا کاربر بیشتر به پرسش‌های پایه‌ای پاسخ می‌دهد یا به مسائل پیشرفته و تخصصی.

چنین امتیاز تخصصی مبتنی بر تحلیل زبان طبیعی می‌تواند جایگزین یا مکمل امتیاز فعلی مبتنی بر رأی کاربران شود و به‌عنوان ورودی به مدل پیش‌بینی‌کننده‌ی سری زمانی داده شود. این رویکرد باعث خواهد شد که مدل به جای پیش‌بینی صرفاً «محبوبیت» آینده‌ی کاربر، مسیر تکامل «دانش واقعی و عمیق» او را با دقت بالاتری

^۱ Policy

^۲ Self-improving

^۳ (NLP) Processing Language Natural

مدل سازی کند.

کتاب نامه

- [1] M. Kobayashi and K. Takeda, "Information retrieval on the web," *ACM Comput. Surv.*, vol.32, pp.144-173, June 2000. Place: New York, NY, USA Publisher: Association for Computing Machinery.
- [2] M. R. Ghorab, D. Zhou, A. O'Connor, and V. Wade, "Personalised Information Retrieval: survey and classification," *User Modeling and User-Adapted Interaction*, vol.23, pp.381-443, Sept. 2013.
- [3] M. Mitra and B. Chaudhuri, "Information Retrieval from Documents: A Survey," *Information Retrieval*, vol.2, pp.141-163, May 2000.
- [4] K. Balog, Y. Fang, M. de Rijke, P. Serdyukov, and L. Si, "Expertise Retrieval," *Foundations and Trends in Information Retrieval*, vol.6, no.2-3, pp.127-256, 2012.
- [5] M. Diaz and A. D. Smith, "What Makes An Expert? Reviewing How ML Researchers Define" Expert", in *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, vol.7, pp.358-370, 2024.
- [6] C. M. Bishop. *Pattern Recognition and Machine Learning* (Information Science and Statistics). Berlin, Heidelberg: Springer-Verlag, 2006.
- [7] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.
- [8] M. Nielsen. *Neural Networks and Deep Learning*. Determination Press, 2015.
- [9] G. Kirchg ssner, J. Wolters, and U. Hassler. *Introduction to modern time series analysis*. Springer Science & Business Media, 2012.
- [10] M. Neshati, "On early detection of high voted Q&A on Stack Overflow," *Information Processing & Management*, vol.53, pp.780-798, July 2017.
- [11] R. Gonçalves and C. F. Dorneles, "Automated expertise retrieval: A taxonomy-based survey and open issues," *ACM Computing Surveys (CSUR)*, vol.52, no.5, pp.1-30, 2019.
- [12] S. Lin, W. Hong, D. Wang, and T. Li, "A survey on expert finding techniques," *Journal of Intelligent Information Systems*, vol.49, pp.255-279, Oct. 2017.

- [13] S. Yuan, Y. Zhang, J. Tang, W. Hall, and J. B. Cabota, "Expert finding in community question answering: a review," *Artificial Intelligence Review*, vol.53, pp.843-874, Feb. 2020.
- [14] S. Rendle, "Factorization machines," in *Proceedings of the 2010 IEEE International Conference on Data Mining*, ICDM '10, (USA), p.995-1000, IEEE Computer Society, 2010.
- [15] K. Hofmann, K. Balog, T. Bogers, and M. de Rijke, "Contextual factors for finding similar experts," *Journal of the American Society for Information Science and Technology*, vol.61, no.5, pp.994-1014, 2010.
- [16] Y. Koren, "Factorization meets the neighborhood: a multifaceted collaborative filtering model," in *Proceedings of the 14th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, KDD '08, (New York, NY, USA), pp.426-434, Association for Computing Machinery, 2008. event-place: Las Vegas, Nevada, USA.
- [17] X. Chen and L. Sun, "Bayesian temporal factorization for multidimensional time series prediction," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol.44, no.9, pp.4659-4673, 2021.
- [18] M. Neshati, Z. Fallahnejad, and H. Beigy, "On dynamicity of expert finding in community question answering," *Information Processing & Management*, vol.53, Sept. 2017.
- [19] P. Rostami and M. Neshati, "Intern retrieval from community question answering websites: A new variation of expert finding problem," *Expert Systems with Applications*, vol.181, Nov. 2021.
- [20] P. Rostami and M. Neshati, "T-shaped grouping: Expert finding models to agile software teams retrieval," *Expert Systems with Applications*, vol.118, pp.303-308, Mar. 2019.
- [21] S. Sotudeh Gharebagh, P. Rostami, and M. Neshati, "T-shaped mining: A novel approach to talent finding for agile software teams," in *40th European Conference on IR Research*, Mar. 2018.
- [22] M. Neshati, H. Beigy, and D. Hiemstra, "Expert group formation using facility location analysis," *Information Processing & Management*, vol.50, no.2, pp.361-383, 2014.
- [23] P. Rostami and A. Shakery, "A deep learning-based expert finding method to retrieve agile software teams from CQAs," *Inf. Process. Manage.*, vol.60, Mar. 2023. Place: USA Publisher: Pergamon Press, Inc.
- [24] M. Azimi, A. Moffat, and J. Zobel, "Expert Finding Revisited: A Uniform Exploration of Methods," in *Proceedings of the 2025 International ACM SIGIR Conference on Innovative Concepts and Theories in Information Retrieval (ICTIR)*, ICTIR '25, (New York, NY, USA), pp.478-487, Association for Computing Machinery, 2025. event-place: Padua, Italy.

- [25] K. F. F. Jiechieu and N. Tsopze, "Skills prediction based on multi-label resume classification using CNN with model predictions explanation," *Neural Computing and Applications*, vol.33, pp.5069-5087, May 2021.
- [26] N. Ghasemi, R. Fatourechi, and S. Momtazi, "User Embedding for Expert Finding in Community Question Answering," *ACM Trans. Knowl. Discov. Data*, vol.15, Mar. 2021. Place: New York, NY, USA Publisher: Association for Computing Machinery.
- [27] S. H. Hashemi, M. Neshati, and H. Beigy, "Expertise retrieval in bibliographic network: a topic dominance learning approach," in *Proceedings of the 22nd ACM International Conference on Information & Knowledge Management*, CIKM '13, (New York, NY, USA), pp.1117-1126, Association for Computing Machinery, 2013. event-place: San Francisco, California, USA.
- [28] A. A. Almuhanha and W. M. S. Yafooz, "Expert Finding In Scholarly Data: An Overview," in *2021 IEEE International IOT, Electronics and Mechatronics Conference (IEMTRONICS)*, pp.1-7, 2021.
- [29] K. Balog and M. de Rijke, "Determining Expert Profiles (With an Application to Expert Finding)," in *IJCAI*, vol.7, pp.2657-2662, Jan. 2007. Issue: 625.
- [30] C. I. Eke, A. A. Norman, L. Shuib, and H. F. Nweke, "A Survey of User Profiling: State-of-the-Art, Challenges, and Solutions," *IEEE Access*, vol.7, pp.144907-144924, 2019.
- [31] J. Tang, L. Yao, D. Zhang, and J. Zhang, "A Combination Approach to Web User Profiling," *ACM Trans. Knowl. Discov. Data*, vol.5, Dec. 2010. Place: New York, NY, USA Publisher: Association for Computing Machinery.
- [32] G. Linden, B. Smith, and J. York, "Amazon.com recommendations: item-to-item collaborative filtering," *IEEE Internet Computing*, vol.7, no.1, pp.76-80, 2003.
- [33] K. Sugiyama, K. Hatano, and M. Yoshikawa, "Adaptive web search based on user profile constructed without any effort from users," in *Proceedings of the 13th International Conference on World Wide Web*, WWW '04, (New York, NY, USA), pp.675-684, Association for Computing Machinery, 2004. event-place: New York, NY, USA.
- [34] L. Han, G. Chen, and M. Li, "A method for the acquisition of ontology-based user profiles," *Adv. Eng. Softw.*, vol.65, pp.132-137, Nov. 2013. Place: GBR Publisher: Elsevier Science Ltd.
- [35] M. Dehghan, M. Biabani, and A. A. Abin, "Temporal expert profiling: With an application to T-shaped expert finding," *Information Processing & Management*, vol.56, no.3, pp.1067-1079, 2019. Publisher: Elsevier.

- [36] W. Fu and S. Akbar, "Expert Profile Identification From Community Detection on Author-Publication-Keyword Graph With Keyword Extraction," *IEEE Access*, vol.12, pp.27918-27930, 2024.
- [37] M. Fazel-Zarandi and M. S. Fox, "Constructing expert profiles over time for skills management and expert finding," in *Proceedings of the 11th International Conference on Knowledge Management and Knowledge Technologies, i-KNOW '11*, (New York, NY, USA), Association for Computing Machinery, 2011. event-place : Graz, Austria.
- [38] M. Iqbal and M. Ahmad, "Ranking and Visualization of Experts for Communication Using LinkedIn," in *Proceedings of the Future Technologies Conference (FTC) 2018* (K. Arai, R. Bhatia, and S. Kapoor, eds.), (Cham), pp.1-12, Springer International Publishing, 2019.
- [39] Z. Liu, Z. Zhu, J. Gao, and C. Xu, "Forecast methods for time series data: A survey," *IEEE Access*, vol.9, pp.91896-91912, 2021.
- [40] A. Mahmoud and A. Mohammed, "A survey on deep learning for time-series forecasting," in *Machine Learning and Big Data Analytics Paradigms: Analysis, Applications and Challenges*, pp.365-392, Cham : Springer International Publishing, 2020.
- [41] Z. Han, J. Zhao, H. Leung, K. F. Ma, and W. Wang, "A review of deep learning models for time series prediction," *IEEE Sensors Journal*, vol.21, no.6, pp.7833-7848, 2019.
- [42] I. Moutidis and H. T. Williams, "Community evolution on stack overflow," *Plos one*, vol.16, no.6, p.e0253010, 2021. Publisher : Public Library of Science San Francisco, CA USA.
- [43] G. Livan, G. Pappalardo, and R. Mantegna, "Quantifying the relationship between specialisation and reputation in an online platform," *Scientific Reports*, vol.12, p.16699, 10 2022.

واژه‌نامه انگلیسی به فارسی

Word کلمه
Word 2 کلمه ۲
Word 3 کلمه ۳

واژه‌نامه فارسی به انگلیسی

word 1 کلمه ۱
word 2 کلمه ۲
word 3 کلمه ۳

Abstract:

In the era of digital transformation, identifying individual expertise is critical for organizations. However, existing approaches in expertise retrieval are inherently static and retrospective, answering only the question, "Who is an expert now?" These models overlook the dynamic evolution of skills, rendering them ineffective for strategic, long-term planning, such as forming teams for future projects. To address this gap, this research, for the first time, formulates the problem of predicting individuals' future expertise as a multivariate time-series forecasting task. Using data from the Stack Overflow website, the annual activity history of users is extracted, and their skill profiles are modeled as a time series. A key challenge is mitigating the effect of platform user growth on scores, which is resolved by introducing an innovative adapter framework based on distinct normalization strategies for training and evaluation. The proposed model, based on a feed-forward neural network, demonstrated its capability in predicting users' skill profiles for the upcoming year. Evaluation results, using the cosine similarity metric, showed that the proposed model achieved a score of 0.8825, a significant improvement over the 0.6485 score of the baseline method. This achievement shifts the paradigm of expertise analysis from retrospective description to future prediction, providing a powerful tool for proactive talent management and mitigating risk in long-term projects.

Keywords: Information Retrieval, Expertise Retrieval, CQA, Machine Learning, Time Series



Shahid Beheshti University
Faculty of Computer Science & Engineering

A Machine Learning-based Approach for Predicting Future Skills of Individuals on Community Question Answering websites

By

sina mohammadi

A THESIS SUBMITTED
FOR THE DEGREE OF
MASTER OF SCIENCE

Supervisor :

Dr. Mahmood Neshati

2025